

6 Lineare Programmierung

6.1 Grundlagen

6.2 Simplex-Algorithmus

6.3 Komplexität von linearer Programmierung

6.4 Ganzzahlige lineare Programme

6 Lineare Programmierung

Lineares Programm (LP): Finde optimale Werte für d **reelle Variablen** $x_1, \dots, x_d \in \mathbb{R}$.

Dabei soll eine **lineare Zielfunktion**

$$c_1 x_1 + \dots + c_d x_d$$

für gegebene Koeffizienten $c_1, \dots, c_d \in \mathbb{R}$ **minimiert** oder **maximiert** werden.

6 Lineare Programmierung

Lineares Programm (LP): Finde optimale Werte für d **reelle Variablen** $x_1, \dots, x_d \in \mathbb{R}$.

Dabei soll eine **lineare Zielfunktion**

$$c_1 x_1 + \dots + c_d x_d$$

für gegebene Koeffizienten $c_1, \dots, c_d \in \mathbb{R}$ **minimiert** oder **maximiert** werden.

Es müssen m **lineare Nebenbedingungen** eingehalten werden. Für jedes $i \in \{1, \dots, m\}$ sind Koeffizienten $a_{i1}, \dots, a_{id} \in \mathbb{R}$ und $b_i \in \mathbb{R}$ gegeben. Eine Belegung der Variablen ist nur dann gültig, wenn sie die folgenden Nebenbedingungen einhält:

$$a_{11}x_1 + \dots + a_{1d}x_d \leq b_1$$

$$\vdots$$

$$a_{m1}x_1 + \dots + a_{md}x_d \leq b_m$$

6 Lineare Programmierung

Lineares Programm (LP): Finde optimale Werte für d **reelle Variablen** $x_1, \dots, x_d \in \mathbb{R}$.

Dabei soll eine **lineare Zielfunktion**

$$c_1 x_1 + \dots + c_d x_d$$

für gegebene Koeffizienten $c_1, \dots, c_d \in \mathbb{R}$ **minimiert** oder **maximiert** werden.

Es müssen m **lineare Nebenbedingungen** eingehalten werden. Für jedes $i \in \{1, \dots, m\}$ sind Koeffizienten $a_{i1}, \dots, a_{id} \in \mathbb{R}$ und $b_i \in \mathbb{R}$ gegeben. Eine Belegung der Variablen ist nur dann gültig, wenn sie die folgenden Nebenbedingungen einhält:

$$a_{11}x_1 + \dots + a_{1d}x_d \leq b_1$$

$$\vdots$$

$$a_{m1}x_1 + \dots + a_{md}x_d \leq b_m$$

Statt \leq ist auch \geq erlaubt.

6 Lineare Programmierung

Sei $x^T = (x_1, \dots, x_d)$ und $c^T = (c_1, \dots, c_d)$.

Damit kann die **Zielfunktion als Skalarprodukt** $c \cdot x$ geschrieben werden.

6 Lineare Programmierung

Sei $x^T = (x_1, \dots, x_d)$ und $c^T = (c_1, \dots, c_d)$.

Damit kann die **Zielfunktion als Skalarprodukt** $c \cdot x$ geschrieben werden.

Außerdem sei $A \in \mathbb{R}^{m \times d}$ die Matrix mit den Einträgen a_{ij} und $b^T = (b_1, \dots, b_m) \in \mathbb{R}^m$.

Dann **entspricht jede Zeile der Matrix einer Nebenbedingung**.

Wir können die Nebenbedingungen als $Ax \leq b$ schreiben.

6 Lineare Programmierung

Sei $x^T = (x_1, \dots, x_d)$ und $c^T = (c_1, \dots, c_d)$.

Damit kann die **Zielfunktion als Skalarprodukt** $c \cdot x$ geschrieben werden.

Außerdem sei $A \in \mathbb{R}^{m \times d}$ die Matrix mit den Einträgen a_{ij} und $b^T = (b_1, \dots, b_m) \in \mathbb{R}^m$.

Dann **entspricht jede Zeile der Matrix einer Nebenbedingung**.

Wir können die Nebenbedingungen als $Ax \leq b$ schreiben.

Lineares Programm

Eingabe: $c \in \mathbb{R}^d, b \in \mathbb{R}^m, A \in \mathbb{R}^{m \times d}$

Lösungen: alle $x \in \mathbb{R}^d$ mit $Ax \leq b$

Zielfunktion: minimiere/maximiere $c \cdot x$

Beispiel:

Ein Hobbygärtner besitzt **100 m² Land**, auf dem er **Blumen** und **Gemüse** anbauen möchte.

- 60 m² Land **geeignet für Blumen und Gemüse**
40 m² **nur für Gemüse geeignet**
- Er hat ein **Budget** in Höhe von 720 €.
- **Kosten für Blumen:** 9 € pro Quadratmeter
Kosten für Gemüse: 6 € pro Quadratmeter
- **Erlös für Blumen:** 20 € pro Quadratmeter
Erlös für Gemüse: 10 € pro Quadratmeter

Frage: Wie viele Blumen und wie viel Gemüse sollte er anbauen, um seinen **Gewinn zu maximieren**?

6 Lineare Programmierung

Wähle geeignete Variablen:

- $x_B \in \mathbb{R} =$ **Quadratmeter Blumen**
- $x_G \in \mathbb{R} =$ **Quadratmeter Gemüse**

Dann können wir die Nebenbedingungen wie folgt formulieren:

$x_B \geq 0, x_G \geq 0$	(keine negative Anbaufläche)
$x_B + x_G \leq 100$	(maximal 100 m ²)
$x_B \leq 60$	(maximal 60 m ² Blumen)
$9x_B + 6x_G \leq 720$	(Budget von 720 €)

6 Lineare Programmierung

Wähle geeignete Variablen:

- $x_B \in \mathbb{R} =$ **Quadratmeter Blumen**
- $x_G \in \mathbb{R} =$ **Quadratmeter Gemüse**

Dann können wir die Nebenbedingungen wie folgt formulieren:

$$x_B \geq 0, x_G \geq 0 \quad (\text{keine negative Anbaufläche})$$

$$x_B + x_G \leq 100 \quad (\text{maximal } 100 \text{ m}^2)$$

$$x_B \leq 60 \quad (\text{maximal } 60 \text{ m}^2 \text{ Blumen})$$

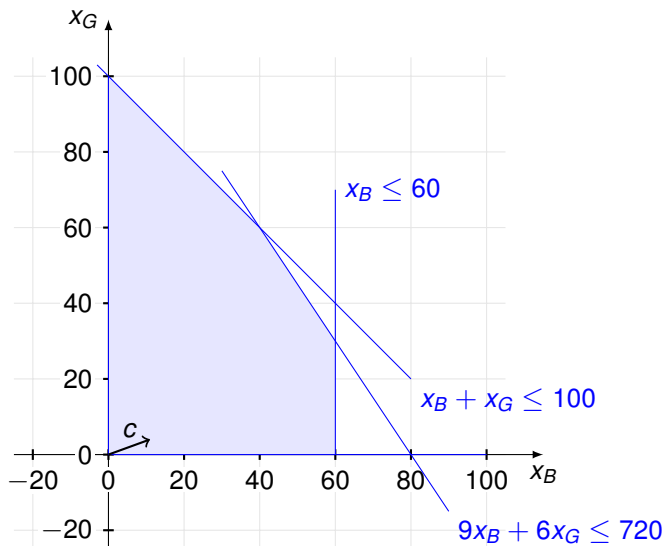
$$9x_B + 6x_G \leq 720 \quad (\text{Budget von } 720 \text{ €})$$

Der Gewinn ist die **Differenz von Erlös und Ausgaben**.

Somit soll die folgende Zielfunktion maximiert werden:

$$(20 - 9)x_B + (10 - 6)x_G = 11x_B + 4x_G.$$

6 Lineare Programmierung



Beispiel: Maximaler Fluss

Eingabe: Flussnetzwerk $G = (V, E)$ mit Quelle $s \in V$ und Senke $t \in V$,
Kapazitätsfunktion $c : E \rightarrow \mathbb{N}_0$

Aufgabe: Finde einen maximalen Fluss von s nach t in G .

6 Lineare Programmierung

Beispiel: Maximaler Fluss

Eingabe: Flussnetzwerk $G = (V, E)$ mit Quelle $s \in V$ und Senke $t \in V$,
Kapazitätsfunktion $c : E \rightarrow \mathbb{N}_0$

Aufgabe: Finde einen maximalen Fluss von s nach t in G .

Modellierung als LP:

Variablen: Für jedes $e \in E$ Variable $x_e \in \mathbb{R}$, die den Fluss auf e angibt.

6 Lineare Programmierung

Beispiel: Maximaler Fluss

Eingabe: Flussnetzwerk $G = (V, E)$ mit Quelle $s \in V$ und Senke $t \in V$,
Kapazitätsfunktion $c : E \rightarrow \mathbb{N}_0$

Aufgabe: Finde einen maximalen Fluss von s nach t in G .

Modellierung als LP:

Variablen: Für jedes $e \in E$ Variable $x_e \in \mathbb{R}$, die den Fluss auf e angibt.

Zielfunktion:

$$\sum_{e=(s,v)} x_e - \sum_{e=(v,s)} x_e$$

6 Lineare Programmierung

Beispiel: Maximaler Fluss

Eingabe: Flussnetzwerk $G = (V, E)$ mit Quelle $s \in V$ und Senke $t \in V$,
Kapazitätsfunktion $c : E \rightarrow \mathbb{N}_0$

Aufgabe: Finde einen maximalen Fluss von s nach t in G .

Modellierung als LP:

Variablen: Für jedes $e \in E$ Variable $x_e \in \mathbb{R}$, die den Fluss auf e angibt.

Zielfunktion:

$$\sum_{e=(s,v)} x_e - \sum_{e=(v,s)} x_e$$

Nebenbedingungen:

$$\forall e \in E : x_e \geq 0 \quad (\text{Fluss nicht negativ})$$

$$\forall e \in E : x_e \leq c(e) \quad (\text{Fluss nicht größer als Kapazität})$$

$$\forall v \in V \setminus \{s, t\} : \sum_{e=(u,v)} x_e - \sum_{e=(v,u)} x_e = 0 \quad (\text{Flusserhaltung})$$

6 Lineare Programmierung

6.1 Grundlagen

6.2 Simplex-Algorithmus

6.3 Komplexität von linearer Programmierung

6.4 Ganzzahlige lineare Programme

6.1 Grundlagen

kanonische Form

$$\min c \cdot x$$

$$Ax \leq b$$

$$x \geq 0$$

Gleichungsform

$$\min c \cdot x$$

$$Ax = b$$

$$x \geq 0$$

6.1 Grundlagen

kanonische Form

$$\min c \cdot x$$

$$Ax \leq b$$

$$x \geq 0$$

Gleichungsform

$$\min c \cdot x$$

$$Ax = b$$

$$x \geq 0$$

Sei $a_i = (a_{i1}, \dots, a_{id})^T \in \mathbb{R}^d$ die i -te Zeile von A .

6.1 Grundlagen

kanonische Form

$$\min c \cdot x$$

$$Ax \leq b$$

$$x \geq 0$$

Gleichungsform

$$\min c \cdot x$$

$$Ax = b$$

$$x \geq 0$$

Sei $a_i = (a_{i1}, \dots, a_{id})^T \in \mathbb{R}^d$ die i -te Zeile von A .

Transformationen

- „maximiere $c \cdot x$ “ entspricht „minimiere $-c \cdot x$ “.

6.1 Grundlagen

kanonische Form

$$\min c \cdot x$$

$$Ax \leq b$$

$$x \geq 0$$

Gleichungsform

$$\min c \cdot x$$

$$Ax = b$$

$$x \geq 0$$

Sei $a_i = (a_{i1}, \dots, a_{id})^T \in \mathbb{R}^d$ die i -te Zeile von A .

Transformationen

- „maximiere $c \cdot x$ “ entspricht „minimiere $-c \cdot x$ “.
- Variable x_i kann durch $x'_i - x''_i$ für zwei Variablen $x'_i \geq 0$ und $x''_i \geq 0$ ersetzt werden.

6.1 Grundlagen

kanonische Form

$$\min c \cdot x$$

$$Ax \leq b$$

$$x \geq 0$$

Gleichungsform

$$\min c \cdot x$$

$$Ax = b$$

$$x \geq 0$$

Sei $a_i = (a_{i1}, \dots, a_{id})^T \in \mathbb{R}^d$ die i -te Zeile von A .

Transformationen

- „maximiere $c \cdot x$ “ entspricht „minimiere $-c \cdot x$ “.
- Variable x_i kann durch $x'_i - x''_i$ für zwei Variablen $x'_i \geq 0$ und $x''_i \geq 0$ ersetzt werden.
- „ $a_i \cdot x \geq b_i$ “ entspricht „ $-a_i \cdot x \leq -b_i$ “.

6.1 Grundlagen

kanonische Form

$$\min c \cdot x$$

$$Ax \leq b$$

$$x \geq 0$$

Gleichungsform

$$\min c \cdot x$$

$$Ax = b$$

$$x \geq 0$$

Sei $a_i = (a_{i1}, \dots, a_{id})^T \in \mathbb{R}^d$ die i -te Zeile von A .

Transformationen

- „maximiere $c \cdot x$ “ entspricht „minimiere $-c \cdot x$ “.
- Variable x_i kann durch $x'_i - x''_i$ für zwei Variablen $x'_i \geq 0$ und $x''_i \geq 0$ ersetzt werden.
- „ $a_i \cdot x \geq b_i$ “ entspricht „ $-a_i \cdot x \leq -b_i$ “.
- Gleichung $a_i \cdot x = b_i$ kann durch $a_i \cdot x \leq b_i$ und $a_i \cdot x \geq b_i$ ersetzt werden.

6.1 Grundlagen

kanonische Form

$$\min c \cdot x$$

$$Ax \leq b$$

$$x \geq 0$$

Gleichungsform

$$\min c \cdot x$$

$$Ax = b$$

$$x \geq 0$$

Sei $a_i = (a_{i1}, \dots, a_{id})^T \in \mathbb{R}^d$ die i -te Zeile von A .

Transformationen

- „maximiere $c \cdot x$ “ entspricht „minimiere $-c \cdot x$ “.
- Variable x_i kann durch $x'_i - x''_i$ für zwei Variablen $x'_i \geq 0$ und $x''_i \geq 0$ ersetzt werden.
- „ $a_i \cdot x \geq b_i$ “ entspricht „ $-a_i \cdot x \leq -b_i$ “.
- Gleichung $a_i \cdot x = b_i$ kann durch $a_i \cdot x \leq b_i$ und $a_i \cdot x \geq b_i$ ersetzt werden.
- $a_i \cdot x \leq b_i$ können wir durch $s_i + a_i \cdot x = b_i$ für eine **Schlupfvariable** $s_i \geq 0$ darstellen.

6.1 Grundlagen

Geometrische Interpretation: Betrachte LP in kanonischer Form

Variablenbelegung $x \in \mathbb{R}^d$ **entspricht Punkt im \mathbb{R}^d .**

6.1 Grundlagen

Geometrische Interpretation: Betrachte LP in kanonischer Form

Variablenbelegung $x \in \mathbb{R}^d$ **entspricht Punkt im \mathbb{R}^d .**

Eine Gleichung $a_i \cdot x = b_i$ definiert eine **affine Hyperebene** $\{x \in \mathbb{R}^d \mid a_i \cdot x = b_i\}$.

Jede solche affine Hyperebene definiert den **abgeschlossenen Halbraum**

$$\mathcal{H}_i = \{x \in \mathbb{R}^d \mid a_i \cdot x \leq b_i\}.$$

6.1 Grundlagen

Geometrische Interpretation: Betrachte LP in kanonischer Form

Variablenbelegung $x \in \mathbb{R}^d$ **entspricht Punkt im \mathbb{R}^d** .

Eine Gleichung $a_i \cdot x = b_i$ definiert eine **affine Hyperebene** $\{x \in \mathbb{R}^d \mid a_i \cdot x = b_i\}$.

Jede solche affine Hyperebene definiert den **abgeschlossenen Halbraum**

$$\mathcal{H}_i = \{x \in \mathbb{R}^d \mid a_i \cdot x \leq b_i\}.$$

Eine Variablenbelegung $x \in \mathbb{R}^d$ **erfüllt genau dann Nebenbedingung i**, wenn $x \in \mathcal{H}_i$ gilt.

Eine Variablenbelegung $x \in \mathbb{R}^d$ ist genau dann **gültig**, wenn

$x \in \mathcal{P} := \mathcal{H}_1 \cap \dots \cap \mathcal{H}_m \cap \mathbb{R}_{\geq 0}^d$ gilt.

6.1 Grundlagen


Beispiel:

Betrachte lineares Programm mit den folgenden Nebenbedingungen

$$x_1 \geq 0, \quad x_2 \geq 0,$$

$$x_1 \leq 2, \quad -x_2 \leq -1,$$

$$-x_1 + x_2 \leq 2$$



6.1 Grundlagen

Wir können $\mathbb{R}_{\geq 0}^d$ als einen Schnitt von d Halbräumen darstellen:

$$\mathbb{R}_{\geq 0}^d = \{x \in \mathbb{R}^d \mid -x_1 \leq 0\} \cap \dots \cap \{x \in \mathbb{R}^d \mid -x_d \leq 0\}.$$

Somit ist \mathcal{P} der **Schnitt von endlich vielen Halbräumen**.

6.1 Grundlagen

Wir können $\mathbb{R}_{\geq 0}^d$ als einen Schnitt von d Halbräumen darstellen:

$$\mathbb{R}_{\geq 0}^d = \{x \in \mathbb{R}^d \mid -x_1 \leq 0\} \cap \dots \cap \{x \in \mathbb{R}^d \mid -x_d \leq 0\}.$$

Somit ist \mathcal{P} der **Schnitt von endlich vielen Halbräumen**.

Einen solchen Schnitt nennt man **Polyeder**. Wir sagen, dass ein lineares Programm **zulässig** ist, wenn sein **Lösungspolyeder** nichtleer ist.

6.1 Grundlagen

Wir können $\mathbb{R}_{\geq 0}^d$ als einen Schnitt von d Halbräumen darstellen:

$$\mathbb{R}_{\geq 0}^d = \{x \in \mathbb{R}^d \mid -x_1 \leq 0\} \cap \dots \cap \{x \in \mathbb{R}^d \mid -x_d \leq 0\}.$$


Somit ist \mathcal{P} der **Schnitt von endlich vielen Halbräumen**.

Einen solchen Schnitt nennt man **Polyeder**. Wir sagen, dass ein lineares Programm **zulässig** ist, wenn sein **Lösungspolyeder** nichtleer ist.


Eine Menge X heißt **konvex**, wenn für alle Punkte $x \in X$ und $y \in X$ gilt:

$$L(x, y) := \{\lambda x + (1 - \lambda)y \mid \lambda \in [0, 1]\} \subseteq X.$$

konvexe Menge



nichtkonvexe Menge



6.1 Grundlagen

Lemma 6.1

Das Lösungspolyeder \mathcal{P} ist konvex.

Beweis: Sei \mathcal{P} der Durchschnitt der abgeschlossenen Halbräume $\mathcal{H}_1, \dots, \mathcal{H}_n$.

6.1 Grundlagen

Lemma 6.1

Das Lösungspolyeder \mathcal{P} ist konvex.

Beweis: Sei \mathcal{P} der Durchschnitt der abgeschlossenen Halbräume $\mathcal{H}_1, \dots, \mathcal{H}_n$.

Jeder abgeschlossene Halbraum $\mathcal{H} = \{z \mid u \cdot z \leq w\}$ ist konvex:

Seien $x \in \mathcal{H}$ und $y \in \mathcal{H}$ beliebig. Für jedes $\lambda \in [0, 1]$ gehört dann auch der Punkt $\lambda x + (1 - \lambda)y$ zu \mathcal{H} , denn

$$u \cdot (\lambda x + (1 - \lambda)y) = \lambda(u \cdot x) + (1 - \lambda)(u \cdot y) \leq \lambda w + (1 - \lambda)w = w.$$

6.1 Grundlagen

Lemma 6.1

Das Lösungspolyeder \mathcal{P} ist konvex.

Beweis: Sei \mathcal{P} der Durchschnitt der abgeschlossenen Halbräume $\mathcal{H}_1, \dots, \mathcal{H}_n$.

Jeder abgeschlossene Halbraum $\mathcal{H} = \{z \mid u \cdot z \leq w\}$ ist konvex:

Seien $x \in \mathcal{H}$ und $y \in \mathcal{H}$ beliebig. Für jedes $\lambda \in [0, 1]$ gehört dann auch der Punkt $\lambda x + (1 - \lambda)y$ zu \mathcal{H} , denn

$$u \cdot (\lambda x + (1 - \lambda)y) = \lambda(u \cdot x) + (1 - \lambda)(u \cdot y) \leq \lambda w + (1 - \lambda)w = w.$$


Der Schnitt zweier konvexer Mengen ist wieder konvex:

Seien $X \subseteq \mathbb{R}^d$ und $Y \subseteq \mathbb{R}^d$ konvexe Mengen, und seien $x, y \in X \cap Y$ beliebig. Da die Mengen X und Y konvex sind, gilt $L(x, y) \subseteq X$ und $L(x, y) \subseteq Y$. Dementsprechend gilt auch $L(x, y) \subseteq X \cap Y$. □

6.1 Grundlagen

Sei ein lineares Programm in kanonischer Form mit Lösungspolyeder \mathcal{P} gegeben.

Wir sagen, eine Variablenbelegung $x \in \mathcal{P}$ ist **lokal optimal**, wenn es ein $\varepsilon > 0$ gibt, für das es kein $y \in \mathcal{P}$ mit $\|x - y\| \leq \varepsilon$ und $c \cdot y < c \cdot x$ gibt¹.




¹Hierbei bezeichnet $\|x - y\|$ den euklidischen Abstand zwischen x und y , also $\|x - y\| = \sqrt{(x_1 - y_1)^2 + \dots + (x_d - y_d)^2}$.

6.1 Grundlagen

Sei ein lineares Programm in kanonischer Form mit Lösungspolyeder \mathcal{P} gegeben.

Wir sagen, eine Variablenbelegung $x \in \mathcal{P}$ ist **lokal optimal**, wenn es ein $\varepsilon > 0$ gibt, für das es kein $y \in \mathcal{P}$ mit $\|x - y\| \leq \varepsilon$ und $c \cdot y < c \cdot x$ gibt¹.




¹Hierbei bezeichnet $\|x - y\|$ den euklidischen Abstand zwischen x und y , also $\|x - y\| = \sqrt{(x_1 - y_1)^2 + \dots + (x_d - y_d)^2}$.

6.1 Grundlagen

Sei ein lineares Programm in kanonischer Form mit Lösungspolyeder \mathcal{P} gegeben.

Wir sagen, eine Variablenbelegung $x \in \mathcal{P}$ ist **lokal optimal**, wenn es ein $\varepsilon > 0$ gibt, für das es kein $y \in \mathcal{P}$ mit $\|x - y\| \leq \varepsilon$ und $c \cdot y < c \cdot x$ gibt¹.



Theorem 6.2

Sei ein lineares Programm in kanonischer Form mit Lösungspolyeder \mathcal{P} gegeben und sei $x \in \mathcal{P}$ eine lokal optimale Variablenbelegung. Dann ist x auch global optimal, d. h. es gibt kein $y \in \mathcal{P}$ mit $c \cdot y < c \cdot x$.

¹Hierbei bezeichnet $\|x - y\|$ den euklidischen Abstand zwischen x und y , also

$$\|x - y\| = \sqrt{(x_1 - y_1)^2 + \dots + (x_d - y_d)^2}.$$

6.1 Grundlagen

Beweis: Annahme: es gibt $y \in \mathcal{P}$ mit $c \cdot y < c \cdot x$.

6.1 Grundlagen

Beweis: Annahme: es gibt $y \in \mathcal{P}$ mit $c \cdot y < c \cdot x$.

Da \mathcal{P} konvex ist, liegt jeder Punkt aus $L(x, y)$ in \mathcal{P} .

Sei $z = \lambda x + (1 - \lambda)y$ mit $\lambda \in [0, 1)$ ein solcher Punkt.

6.1 Grundlagen

Beweis: Annahme: es gibt $y \in \mathcal{P}$ mit $c \cdot y < c \cdot x$.

Da \mathcal{P} konvex ist, liegt jeder Punkt aus $L(x, y)$ in \mathcal{P} .

Sei $z = \lambda x + (1 - \lambda)y$ mit $\lambda \in [0, 1)$ ein solcher Punkt.

Zielfunktion an der Stelle z :

$$c \cdot z = c \cdot (\lambda x + (1 - \lambda)y) = \lambda(c \cdot x) + (1 - \lambda)(c \cdot y) < c \cdot x.$$

6.1 Grundlagen

Beweis: Annahme: es gibt $y \in \mathcal{P}$ mit $c \cdot y < c \cdot x$.

Da \mathcal{P} konvex ist, liegt jeder Punkt aus $L(x, y)$ in \mathcal{P} .

Sei $z = \lambda x + (1 - \lambda)y$ mit $\lambda \in [0, 1)$ ein solcher Punkt.

Zielfunktion an der Stelle z :

$$c \cdot z = c \cdot (\lambda x + (1 - \lambda)y) = \lambda(c \cdot x) + (1 - \lambda)(c \cdot y) < c \cdot x.$$

\Rightarrow Jeder Punkt $z \in L(x, y)$ mit $z \neq x$ ist eine echt bessere Variablenbelegung als x . \square

6.1 Grundlagen

Ein LP heißt **unbeschränkt**, wenn der zu minimierende Zielfunktionswert innerhalb des Lösungspolyeders \mathcal{P} beliebig klein werden kann. Ansonsten heißt es **beschränkt**.

6.1 Grundlagen

Ein LP heißt **unbeschränkt**, wenn der zu minimierende Zielfunktionswert innerhalb des Lösungspolyeders \mathcal{P} beliebig klein werden kann. Ansonsten heißt es **beschränkt**.

Sei $c \cdot x$ eine beliebige lineare Zielfunktion und sei $w \in \mathbb{R}$ beliebig. Die Menge

$$\{x \in \mathbb{R}^d \mid c \cdot x = w\}$$

bildet eine **affine Hyperebene mit Normalenvektor c** .

6.1 Grundlagen


Ein LP heißt **unbeschränkt**, wenn der zu minimierende Zielfunktionswert innerhalb des Lösungspolyeders \mathcal{P} beliebig klein werden kann. Ansonsten heißt es **beschränkt**.

Sei $c \cdot x$ eine beliebige lineare Zielfunktion und sei $w \in \mathbb{R}$ beliebig. Die Menge

$$\{x \in \mathbb{R}^d \mid c \cdot x = w\}$$

bildet eine **affine Hyperebene mit Normalenvektor c** .

1. Finde ein $w \in \mathbb{R}$, sodass $\{x \in \mathbb{R}^d \mid c \cdot x = w\} \cap \mathcal{P} \neq \emptyset$.



6.1 Grundlagen


Ein LP heißt **unbeschränkt**, wenn der zu minimierende Zielfunktionswert innerhalb des Lösungspolyeders \mathcal{P} beliebig klein werden kann. Ansonsten heißt es **beschränkt**.

Sei $c \cdot x$ eine beliebige lineare Zielfunktion und sei $w \in \mathbb{R}$ beliebig. Die Menge

$$\{x \in \mathbb{R}^d \mid c \cdot x = w\}$$

bildet eine **affine Hyperebene mit Normalenvektor c** .

1. Finde ein $w \in \mathbb{R}$, sodass $\{x \in \mathbb{R}^d \mid c \cdot x = w\} \cap \mathcal{P} \neq \emptyset$.
2. Verschiebe $\{x \in \mathbb{R}^d \mid c \cdot x = w\}$ solange parallel in Richtung $-c$ wie obiger Schnitt nichtleer ist.



6.1 Grundlagen


Ein LP heißt **unbeschränkt**, wenn der zu minimierende Zielfunktionswert innerhalb des Lösungspolyeders \mathcal{P} beliebig klein werden kann. Ansonsten heißt es **beschränkt**.

Sei $c \cdot x$ eine beliebige lineare Zielfunktion und sei $w \in \mathbb{R}$ beliebig. Die Menge

$$\{x \in \mathbb{R}^d \mid c \cdot x = w\}$$

bildet eine **affine Hyperebene mit Normalenvektor c** .

1. Finde ein $w \in \mathbb{R}$, sodass $\{x \in \mathbb{R}^d \mid c \cdot x = w\} \cap \mathcal{P} \neq \emptyset$.
2. Verschiebe $\{x \in \mathbb{R}^d \mid c \cdot x = w\}$ solange parallel in Richtung $-c$ wie obiger Schnitt nichtleer ist.



6.1 Grundlagen


Ein LP heißt **unbeschränkt**, wenn der zu minimierende Zielfunktionswert innerhalb des Lösungspolyeders \mathcal{P} beliebig klein werden kann. Ansonsten heißt es **beschränkt**.

Sei $c \cdot x$ eine beliebige lineare Zielfunktion und sei $w \in \mathbb{R}$ beliebig. Die Menge

$$\{x \in \mathbb{R}^d \mid c \cdot x = w\}$$

bildet eine **affine Hyperebene mit Normalenvektor c** .

1. Finde ein $w \in \mathbb{R}$, sodass $\{x \in \mathbb{R}^d \mid c \cdot x = w\} \cap \mathcal{P} \neq \emptyset$.
2. Verschiebe $\{x \in \mathbb{R}^d \mid c \cdot x = w\}$ solange parallel in Richtung $-c$ wie obiger Schnitt nichtleer ist.



6.1 Grundlagen


Ein LP heißt **unbeschränkt**, wenn der zu minimierende Zielfunktionswert innerhalb des Lösungspolyeders \mathcal{P} beliebig klein werden kann. Ansonsten heißt es **beschränkt**.

Sei $c \cdot x$ eine beliebige lineare Zielfunktion und sei $w \in \mathbb{R}$ beliebig. Die Menge

$$\{x \in \mathbb{R}^d \mid c \cdot x = w\}$$

bildet eine **affine Hyperebene mit Normalenvektor c** .

1. Finde ein $w \in \mathbb{R}$, sodass $\{x \in \mathbb{R}^d \mid c \cdot x = w\} \cap \mathcal{P} \neq \emptyset$.
2. Verschiebe $\{x \in \mathbb{R}^d \mid c \cdot x = w\}$ solange parallel in Richtung $-c$ wie obiger Schnitt nichtleer ist.



6.1 Grundlagen


Ein LP heißt **unbeschränkt**, wenn der zu minimierende Zielfunktionswert innerhalb des Lösungspolyeders \mathcal{P} beliebig klein werden kann. Ansonsten heißt es **beschränkt**.

Sei $c \cdot x$ eine beliebige lineare Zielfunktion und sei $w \in \mathbb{R}$ beliebig. Die Menge

$$\{x \in \mathbb{R}^d \mid c \cdot x = w\}$$


bildet eine **affine Hyperebene mit Normalenvektor c** .

1. Finde ein $w \in \mathbb{R}$, sodass $\{x \in \mathbb{R}^d \mid c \cdot x = w\} \cap \mathcal{P} \neq \emptyset$.
2. Verschiebe $\{x \in \mathbb{R}^d \mid c \cdot x = w\}$ solange parallel in Richtung $-c$ wie obiger Schnitt nichtleer ist.
3. Terminiert der zweite Schritt nicht, so ist das LP unbeschränkt. Ansonsten sei $\mathcal{A} = \{x \in \mathbb{R}^d \mid c \cdot x = w\}$ die letzte Hyperebene mit $\mathcal{A} \cap \mathcal{P} \neq \emptyset$. Dann ist jeder Punkt $x^* \in \mathcal{A} \cap \mathcal{P}$ eine optimale Variablenbelegung des LPs.



6.1 Grundlagen

Beispiele:



6 Lineare Programmierung

6.1 Grundlagen

6.2 Simplex-Algorithmus

6.3 Komplexität von linearer Programmierung

6.4 Ganzzahlige lineare Programme


6.2 Simplex-Algorithmus

Simplex-Algorithmus (informelle Beschreibung)

Starte an einer Ecke $x^1 \in \mathcal{P}$ und teste, ob es eine benachbarte Ecke mit besserem Zielfunktionswert gibt.

Gibt es eine solche benachbarte Ecke $x^2 \in \mathcal{P}$, so mache mit x^2 analog weiter und teste, ob es eine **bessere benachbarte Ecke** gibt.

Den Übergang von einer Ecke zu einer besseren in der Nachbarschaft nennen wir auch **Pivotschritt**.




6.2 Simplex-Algorithmus

Simplex-Algorithmus (informelle Beschreibung)

Starte an einer Ecke $x^1 \in \mathcal{P}$ und teste, ob es eine benachbarte Ecke mit besserem Zielfunktionswert gibt.

Gibt es eine solche benachbarte Ecke $x^2 \in \mathcal{P}$, so mache mit x^2 analog weiter und teste, ob es eine **bessere benachbarte Ecke** gibt.

Den Übergang von einer Ecke zu einer besseren in der Nachbarschaft nennen wir auch **Pivotschritt**.




6.2 Simplex-Algorithmus

Simplex-Algorithmus (informelle Beschreibung)

Starte an einer Ecke $x^1 \in \mathcal{P}$ und teste, ob es eine benachbarte Ecke mit besserem Zielfunktionswert gibt.

Gibt es eine solche benachbarte Ecke $x^2 \in \mathcal{P}$, so mache mit x^2 analog weiter und teste, ob es eine **bessere benachbarte Ecke** gibt.

Den Übergang von einer Ecke zu einer besseren in der Nachbarschaft nennen wir auch **Pivotschritt**.




6.2 Simplex-Algorithmus

Simplex-Algorithmus (informelle Beschreibung)

Starte an einer Ecke $x^1 \in \mathcal{P}$ und teste, ob es eine benachbarte Ecke mit besserem Zielfunktionswert gibt.

Gibt es eine solche benachbarte Ecke $x^2 \in \mathcal{P}$, so mache mit x^2 analog weiter und teste, ob es eine **bessere benachbarte Ecke** gibt.

Den Übergang von einer Ecke zu einer besseren in der Nachbarschaft nennen wir auch **Pivotschritt**.




6.2 Simplex-Algorithmus

Simplex-Algorithmus (informelle Beschreibung)

Starte an einer Ecke $x^1 \in \mathcal{P}$ und teste, ob es eine benachbarte Ecke mit besserem Zielfunktionswert gibt.

Gibt es eine solche benachbarte Ecke $x^2 \in \mathcal{P}$, so mache mit x^2 analog weiter und teste, ob es eine **bessere benachbarte Ecke** gibt.

Den Übergang von einer Ecke zu einer besseren in der Nachbarschaft nennen wir auch **Pivotschritt**.





6.2 Simplex-Algorithmus

Simplex-Algorithmus (informelle Beschreibung)

Starte an einer Ecke $x^1 \in \mathcal{P}$ und teste, ob es eine benachbarte Ecke mit besserem Zielfunktionswert gibt.

Gibt es eine solche benachbarte Ecke $x^2 \in \mathcal{P}$, so mache mit x^2 analog weiter und teste, ob es eine **bessere benachbarte Ecke** gibt.

Den Übergang von einer Ecke zu einer besseren in der Nachbarschaft nennen wir auch **Pivotschritt**.





6.2 Simplex-Algorithmus

Simplex-Algorithmus (informelle Beschreibung)

Starte an einer Ecke $x^1 \in \mathcal{P}$ und teste, ob es eine benachbarte Ecke mit besserem Zielfunktionswert gibt.

Gibt es eine solche benachbarte Ecke $x^2 \in \mathcal{P}$, so mache mit x^2 analog weiter und teste, ob es eine **bessere benachbarte Ecke** gibt.

Den Übergang von einer Ecke zu einer besseren in der Nachbarschaft nennen wir auch **Pivotschritt**.





6.2 Simplex-Algorithmus

Simplex-Algorithmus (informelle Beschreibung)

Starte an einer Ecke $x^1 \in \mathcal{P}$ und teste, ob es eine benachbarte Ecke mit besserem Zielfunktionswert gibt.

Gibt es eine solche benachbarte Ecke $x^2 \in \mathcal{P}$, so mache mit x^2 analog weiter und teste, ob es eine **bessere benachbarte Ecke** gibt.

Den Übergang von einer Ecke zu einer besseren in der Nachbarschaft nennen wir auch **Pivotschritt**.



6.2 Simplex-Algorithmus

Finden einer initialen Lösung

Sei ein LP mit den Nebenbedingungen $Ax = b$ gegeben und sei o. B. d. A. $b \geq 0$.

6.2 Simplex-Algorithmus

Finden einer initialen Lösung

Sei ein LP mit den Nebenbedingungen $Ax = b$ gegeben und sei o. B. d. A. $b \geq 0$.

Für die m Nebenbedingungen führen wir **Hilfsvariablen** $h_1 \geq 0, \dots, h_m \geq 0$ ein.

Die NB $a_i \cdot x = b_i$ ersetzen wir für jedes i durch die NB $a_i \cdot x + h_i = b_i$.

Wir ignorieren die Zielfunktion und definieren als **neue Zielfunktion** $h_1 + \dots + h_m$.

6.2 Simplex-Algorithmus

Finden einer initialen Lösung

Sei ein LP mit den Nebenbedingungen $Ax = b$ gegeben und sei o. B. d. A. $b \geq 0$.

Für die m Nebenbedingungen führen wir **Hilfsvariablen** $h_1 \geq 0, \dots, h_m \geq 0$ ein.

Die NB $a_i \cdot x = b_i$ ersetzen wir für jedes i durch die NB $a_i \cdot x + \mathbf{h_i} = b_i$.

Wir ignorieren die Zielfunktion und definieren als **neue Zielfunktion** $h_1 + \dots + h_m$.

Zulässige Lösung für dieses LP:

$h_i = b_i$ für jedes $i \in \{1, \dots, m\}$ und $x_i = 0$ für alle $i \in \{1, \dots, d\}$.

6.2 Simplex-Algorithmus

Finden einer initialen Lösung

Sei ein LP mit den Nebenbedingungen $Ax = b$ gegeben und sei o. B. d. A. $b \geq 0$.

Für die m Nebenbedingungen führen wir **Hilfsvariablen** $h_1 \geq 0, \dots, h_m \geq 0$ ein.

Die NB $a_i \cdot x = b_i$ ersetzen wir für jedes i durch die NB $a_i \cdot x + h_i = b_i$.

Wir ignorieren die Zielfunktion und definieren als **neue Zielfunktion** $h_1 + \dots + h_m$.

Zulässige Lösung für dieses LP:

$h_i = b_i$ für jedes $i \in \{1, \dots, m\}$ und $x_i = 0$ für alle $i \in \{1, \dots, d\}$.

Initialisiere Simplex-Algorithmus mit dieser Lösung und berechne eine opt. Lösung (x^*, h^*) .

Gilt $h^* \neq 0$, dann ist das ursprüngliche LP **nicht zulässig**.

6.2 Simplex-Algorithmus

Finden einer initialen Lösung

Sei ein LP mit den Nebenbedingungen $Ax = b$ gegeben und sei o. B. d. A. $b \geq 0$.

Für die m Nebenbedingungen führen wir **Hilfsvariablen** $h_1 \geq 0, \dots, h_m \geq 0$ ein.

Die NB $a_i \cdot x = b_i$ ersetzen wir für jedes i durch die NB $a_i \cdot x + \mathbf{h_i} = b_i$.

Wir ignorieren die Zielfunktion und definieren als **neue Zielfunktion** $h_1 + \dots + h_m$.

Zulässige Lösung für dieses LP:

$h_i = b_i$ für jedes $i \in \{1, \dots, m\}$ und $x_i = 0$ für alle $i \in \{1, \dots, d\}$.

Initialisiere Simplex-Algorithmus mit dieser Lösung und berechne eine opt. Lösung (x^*, h^*) .

Gilt $h^* \neq 0$, dann ist das ursprüngliche LP **nicht zulässig**.

Gilt $h^* = 0$, dann ist x^* eine **zulässige Lösung für das ursprüngliche LP**.