# C-Crash-Kurs für Java-Programmierer

"Systemnahe Programmierung" (BA-INF 034) im Wintersemester 2020/2021

Dr. Matthias Frank, Dr. Matthias Wübbeling

Institut für Informatik 4 Universität Bonn

e-mail: {matthew, matthias.wuebbeling}@cs.uni-bonn.de Sprechstunde: nach der Vorlesung bzw. nach Vereinbarung

# Vergleich Java und C

 Java und C nutzen fast gleiche Syntax, aber unterschiedliche Konzepte:

#### Java

- Objektorientiert
  - Objekte, Kapselung, Vererbung
- Interpretiert
  - JVM, portabel, feste Typgrößen
- Automatische Speicherverwaltung
  - new, Garbage Collector
- Strenge Typprüfung
  - Keine Zeiger, eingeschränkte Casts, Indexprüfung zur Laufzeit

#### C

- Prozedural
  - Funktionen, globale Variablen
- Übersetzt
  - Maschinensprache, Typgrößen hardwareabhängig
- Manuelle Speicherverwaltung
  - Zeiger, malloc()/free()
- Schwache Typprüfung
  - Beliebige casts, keine Überprüfungen zur Laufzeit

#### Warum C?

C ist eine alte Sprache, Java (relativ) modern. C ist voller Fallstricke:

- Der Entwickler muss viel mehr "selber machen":
  - Speicher reservieren (freigeben nicht vergessen!)
  - Sicherstellen, dass alle Programmteile genau wissen, wie verwendete Daten strukturiert sind (Position, Größe, ...)
- C ist fehleranfälliger
  - Sowohl Compiler als auch Laufzeitumgebung überprüfen weniger (Variableninitialisierung, ...)
  - Zeiger erlauben das Lesen und Schreiben an (fast) beliebiger
     Stelle im Speicher

ABER: Hinweis auf clang bei SysProg im WS14/15 (vgl. Ü1)

#### Warum C?

# Warum wird trotzdem C für systemnahes Programmieren eingesetzt?

- Unix, Linux und Windows sind alle in C geschrieben!
  - Datenstrukturen und APIs des Betriebssystems in C am "natürlichsten" nutzbar
- Schneller als Java, C++, ...
  - Nicht interpretiert wie bei Java
  - Kein OO-Overhead wie bei C++
- Totale Kontrolle
  - Keine Sandbox
  - Kein Garbage Collector (Timing!)
- "Systemnah" bedeutet oft Bits und Bytes herum schieben
  - Netzwerkpakete, I/O-Ansteuerung, ...
  - In C meist mit weniger Aufwand verbunden als in Java

#### HelloWorld.c

#### Übersetzen

Ein C-Programm muss vor dem Starten in eine ausführbare

Datei übersetzt werden:

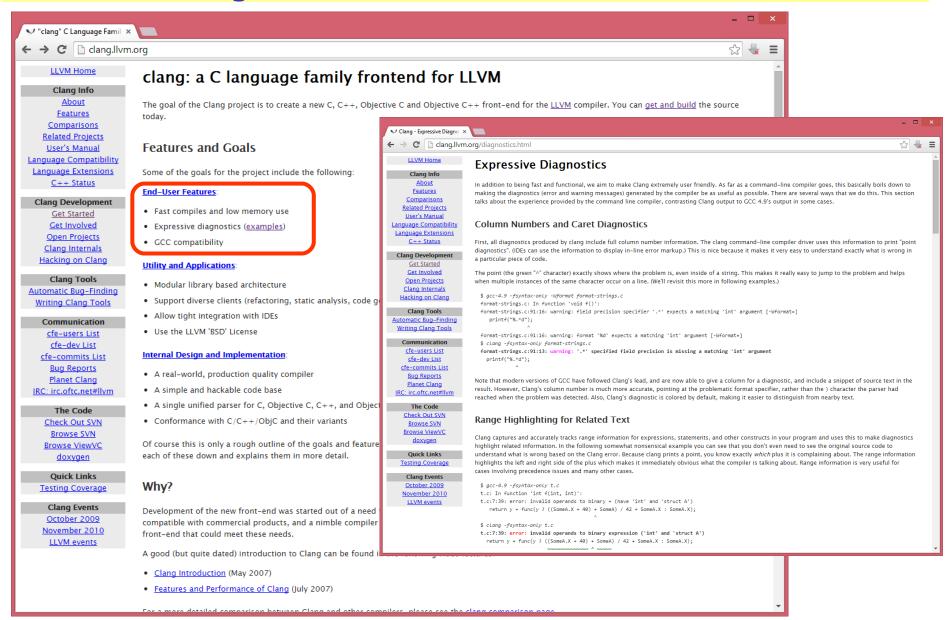
ABER: Hinweis auf clang bei
SysProg im WS14/15 (vgl. Ü1)

- gcc (Linux), MS Visual C++ (Windows), ...
- Hier in der SysProg: gcc (GNU C Compiler)

Schritte beim Übersetzen (siehe auch SysInf Kap. 2):

- Präprozessor
  - Verarbeitet alle Präprozessor-Direktiven im Sourcecode (Makros, ...)
- Übersetzer (Compiler)
  - Übersetzt den vorverarbeiteten Sourcecode in Maschinensprache: Objektdatei(en)
- Binder (Linker)
  - Bindet die Objektdateien und Bibliotheken zu einer ausführbaren Datei

# Alternative zu gcc



# Übersetzen mit gcc

Alle drei Schritte (Präprozessor, Übersetzen, Binden) erledigt gcc in der Voreinstellung automatisch:

```
$ gcc HelloWord.c
```

- Erzeugt aus "HelloWorld.c" die ausführbare Datei "a.out"
- \$ gcc HelloWorld.c -o HelloWorld
  - Nennt die ausführbare Datei "HelloWorld" (statt "a.out")

#### Hilfreiche Optionen von gcc:

- Wall alle Warnungen einschalten
- g
   Symbolnamen in Objektdatei einfügen zum Debuggen

Für mehr Informationen: "man gcc"!

Dateinamen und Optionen jedes Mal in der Kommandozeile anzugeben ist umständlich. Lösung: Makefile (Übungsblatt 1!)

#### Beispiel: backwards.c

```
/* für malloc(), free() */
#include <stdlib.h>
#include <stdio.h>
                               /* für printf() */
                               /* für strlen() */
#include <string.h>
#include "backwards.h"
                               /* eigene Definitionen */
                           // Zeiger auf Zielpuffer
char *buffer, *dest;
int main(int argc, char **argv) {
   int i, j;
  buffer = malloc(BUFFER SIZE); // Speicher reservieren
   for (i = argc-1; i > 0; i--) { // Rückwärts über alle Argumente
    for (j = strlen(argv[i]) - 1; j \ge 0; j--) { // Rückwärts über}
                                              // aktuelles Argument
      *dest++ = argv[i][j]; // char in Puffer schreiben
    *dest++ = ' ';
                           // Wörter mit Leerzeichen trennen
   *dest=0;
                           // Ergebnis mit null terminieren
  printf("%s\n", buffer);
                          // ... und ausgeben
   free(buffer);
                           // Speicher freigeben
}
```

Laufe rückwärts über alle Argumente

Laufe rückwärts über alle Zeichen des aktuellen Arguments

Kopiere Zeichen in Puffer

Trenne Wörter durch Leerzeichen

Gib Puffer aus

#### backwards.c

Wie sieht die Ausgabe des Programms aus?

```
$ ./backwards uni_bonn
nnob_inu
$ ./backwards systemnahe programmierung
gnureimmargorp ehanmetsys
$
```

Das Programm "backwards.c" ist weder systemnah noch sonderlich sinnvoll…

- ...aber nutzt C-typische Features (includes, Zeiger, Speichermanagement, Strings, ...)
- ...und enthält einen C-typischen Fehler!

# **Struktur eines C-Programms**

#### Includes

#### Globale Variablen

# main()

weitere Funktionen (vor oder nach main)

```
#include <stdlib.h>
                       /* für malloc(), free() */
#include <stdio.h>
                       /* für printf() */
                      /* für strlen() */
#include <string.h>
#include "backwards.h"
                       /* eigene Definitionen */
int main(int argc, char **argv) {
  int i, j;
  dest = buffer;
                              // Zeiger merken
  for (i = argc-1; i > 0; i--) { // Rückwärts über alle
                               // Argumente
    for (j = strlen(argv[i])-1; j \ge 0; j--) \{ // Rückwärts über
                                       // aktuelles Argument
     *dest++ = argv[i][j];
                           // char in Puffer schreiben
    *dest++ = ' '; // Wörter mit Leerzeichen trennen
  *dest=0;
                       // Ergebnis mit null terminieren
  printf("%s\n", buffer); // ...und ausgeben
  free(buffer);
                       // Speicher freigeben
```

#### **Präprozessor**

Anweisungen, die mit "#" beginnen, werden vom Präprozessor vor der eigentlichen Übersetzung verarbeitet.

#include <...> ist ähnlich zu Java import und bindet andere Sourcecode-Dateien in den Quelltext ein, meist Funktionsbibliotheken.

- stdio.h: Ein-/Ausgabefunktionen
- stdlib.h: Standardfunktionen und Makros
- math.h: Mathematische Funktionen
- string.h: String-Funktionen
- ...mehr im Laufe der Vorlesung, z.B. für Netzwerksockets, ...

#### **Präprozessor**

Hier wird Speicher reserviert – aber wie viel?

Was ist der Wert von BUFFER\_SIZE?

Mittels #include "..." werden (eigene) Header-Dateien (aus dem selben Verzeichnis) mit Definitionen eingebunden.

Typischerweise gehört zu jeder .c-Datei eine entsprechende .h-Datei.

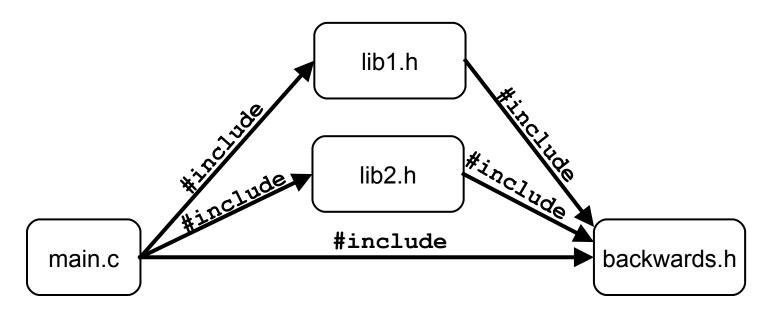
#### backwards.h

```
#ifndef _BACKWARDS_H
    #define _BACKWARDS_H
    #define BUFFER_SIZE 32
#endif
```

- #define: definiert Konstanten und Makros
  - Hier: Jedes Vorkommen von "BUFFER\_SIZE" wird im einbindenden Sourcecode vom Präprozessor durch "32" ersetzt
  - Erst danach wird die so veränderte Datei übersetzt
  - Vorsicht: Kein ";" am Ende der Zeile! Dieses würde sonst ebenfalls eingefügt und kann beim Übersetzen zu schwer zu findenden Fehlern führen!

 Funktionssignaturen usw. können ebenfalls hier deklariert bzw. definiert werden

#### backwards.h



- Im Beispiel: backward.h mehrfach von main.c inkludiert
  - einmal direkt, zweimal indirekt
  - ⇒ Problem: mehrfache Deklarationen und Definitionen
  - ⇒ Prüfen ob backwards.h bereits inkludiert
- #ifdef/#ifndef: entspricht "if x is defined/not defined..."
  - Hier: Sorgt dafür, dass <u>BUFFER\_SIZE</u> nur einmal definiert wird, egal wie viele Dateien "backwards.h" per <u>#include</u> einbinden – typisch für .h-Dateien

# main()

#### Jedes C-Programm hat genau eine main-Methode:

```
int main(int argc, char **argv) {
}
```

Ähnlich wie bei Java beginnt hier der Programmfluss.

- Rückgabewert int: 0 = ok, 1=Fehler
  - Nichts zurückgeben klappt aber auch… ©
- int argc: Anzahl Argumente
  - Mindestens 1, da Programmname immer als erstes Argument übergeben wird
- char \*\*argv (oder auch char \*argv[]): Zeiger auf Argumente
  - Genauer: Zeiger auf Zeiger auf char
  - Gleich mehr zu Zeigern und Strings...
  - argv[0] enthält immer den Name des Programms

# **Modulares Programmieren und Linken**

#### Modul fibo:

```
Datei fibo.h:

#ifndef fibo_h
#define fibo_h

/* berechnet n-te Fibonaccizahl */
int fibo(int n);
#endif
```

```
Datei fibo.c:
#include "fibo.h"

int fibo(int n) {
  if (n < 2) return 1;
  else return fibo(n-1)+fibo(n-2);
}</pre>
```

```
Hauptprogramm, Datei main.c
#include <stdio.h>
#include "fibo.h"
int main() {
  int j;
  for (j=1; j<10; j++)
    printf("%d\n", fibo(j));
  return 0;
}</pre>
```

```
Modul fibo kompilieren:

gcc -Wall -c fibo.c 

Hauptprogramm kompilieren:

gcc -Wall -c main.c 

main.o

Modul und Hauptprogramm zu ausführbarem

Programm binden/linken:

gcc main.o fibo.o 

a.out
```

#### Konstanten und Variablen

Konstanten und Variablen musten vor ihrer ersten Benutzung deklariert werden:

```
int main(int argc, char **argv) {

int main(int argc, char **argv) {

int r, j:

buffer = mallor(boffer_CTZE); // Speicher reservieren

dest = buffer; // Zeiger merken

for (i = argc-1; i > 0; i--) { // Rückwärts über alle Argumente

for (j = strlen(argv[i])-1; j >= 0; j--) { // Rückwärts

// über aktuelles Argument

...
```

Gleichzeitig deklarieren und verwenden (wie in Java möglich) ist "seit neustem" auch möglich (C99):

Java/C:

```
for (int i = argc-1; i > 0; i--) { // Rückwärts über alle Argumente for (int j = strlen(argv[i])-1; j >= 0; j--) { // Rückwärts // über aktuelles Argument
```

#### Konstanten und Variablen

In C gibt es nicht nur lokale, sondern auch globale Konstanten und Variablen:

```
Global, Zugriff
möglich von überall

Lokal, nur in main()
verwendbar

—

char *buffer, *dest; // Zeiger auf Zielpuffer
int main(int argc, char **argv) {

int i, j;

...

}

...
```

- Variablen i und j können nur in main() "gesehen" werden
- buffer und dest können von jeder Funktion (innerhalb derselben Datei) gelesen und überschrieben werden!
  - Vorteil: Weniger Parameter an Funktionen zu übergeben
  - Nachteil: Fehleranfälliger (keine Kapselung, Seiteneffekte)
  - Vorsicht: Lokale Variablen können globale Variablen "überdecken", z.B. "int buffer;" in main()! Wird mit -Wall angezeigt

# **Datentypen**

- Größe eines Datentyps ist nicht fix, sondern hardwareabhängig!
  - Java: int ist immer 4 Byte
  - C: 4 Byte für gcc/i386, 2 Byte für viele embedded devices, ...
  - Tatsächliche Größe eines Typs: z.B. sizeof(int), Werte zwischen INT MIN und INT MAX
- C unterstützt vorzeichenlose Typen:
  - unsigned int, unsigned char, ...
- Es gibt keinen Datentyp boolean wie in Java!
  - Stattdessen: int, mit 0 = false, alles andere = true
    - if (0) {...}: Wird nicht ausgeführt
    - if (42) {...}: Wird ausgeführt

# **Datentypkonvertierung**

- Explizite/manuelle Datentypkonvertierung (Typecasting)
   möglich (Datentyp) EXPRESSION
- Beispiel: Dividieren wir zwei Ganzzahlen (int)
  - so wird eine Ganzzahldivision durchgeführt
  - entstehender Rest wird verworfen
  - also ergibt 1/2 den Wert 0 und 7/3 hätte den Wert 2
- Durch explizites Typecasting kann hier anderes Verhalten erzwungen werden:

```
int x = 1, y = 2;
double half = (double)x/y; // nun hat half den Wert 0.5
```

#### **Strukturen**

#### Mit struct erstellt man kombinierte Datentypen:

```
struct point2d {
   double x, y;
};

struct point2d firstpoint;
firstpoint.x = 2.0;
firstpoint.y = 5.6;
```

```
struct rect2d {
   struct point2d topleft,
   topright, bottomleft,
   bottomright;
};

struct rect2d r;
r.topleft.x = 4;
```

- Jede Variable vom Typ point2d muss "struct" in der Deklaration haben
- ";" am Ende nicht vergessen!
- Zugriff auf Elemente der Struktur mit dem Selektor "."
  - Schachtelung möglich!
  - Zugriff wieder mit dem Selektor "."

# Adressen und Zeiger

- Adressoperator & liefert Adresse einer Variablen
- Zeiger: Variablen, die als Werte Adressen anderer Variablen enthalten ("zeigen auf andere Variablen")
  - Analog alpha-Notation: Indirekte Adressierung (SysInf Kap. 1.3.4.5)
    - ρ(ρ(i)): Inhalt der Speicherzelle, deren Adresse in Speicherzelle i steht

```
• int c;
Eine Variable vom Typ int
```

- int \*c; Ein Zeiger auf eine Variable vom Typ int
- int \*c = &d; Ein Zeiger auf die Adresse der Variable d
  - Dieser Zeiger kann sich ändern! Man kann int \*c also auf verschiedene Variablen vom Typ int zeigen lassen
- Dereferenzierungsoperator \* liefert Variable aus/zu einem Zeiger
  - Invers zum Adressoperator: \*(&c) liefert c

# **Zeiger und Felder**

- int vektor[3];
  - Feld mit drei Integer-Komponenten vektor[0], vektor[1], vektor[2]
- vektor gibt Adresse der ersten Komponente an und kann als Zeiger auf die erste Komponente aufgefasst werden
- vektor und &vektor[0] sind gleichbedeutend

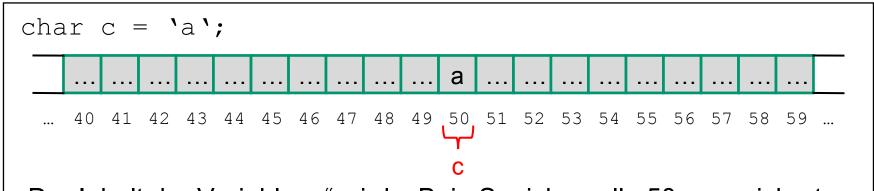
# Zeigerarithmetik und Felder

 Größe eines Datentyps = Anzahl der Bytes die eine Variable des Datentyps im Speicher belegt

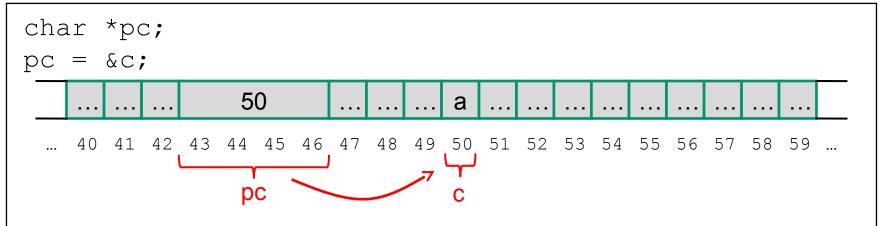
```
- sizeof(datentyp); sizeof(int);
- sizeof(variablenname); int i; sizeof(i);
```

- Zeigerarithmetik
  - Additive Verknüpfung von Zeigern und ganzen Zahlen
  - Zeiger/Pointer und ganze Zahl z: p + z
    - ⇒ zu Adresse p wird das z-fache von d addiert, wobei d die Größe des Datentyps ist, den p referenziert
  - vektor[i] gleichbedeutend mit \*(vektor + i)

# **Zeiger und Speicher**



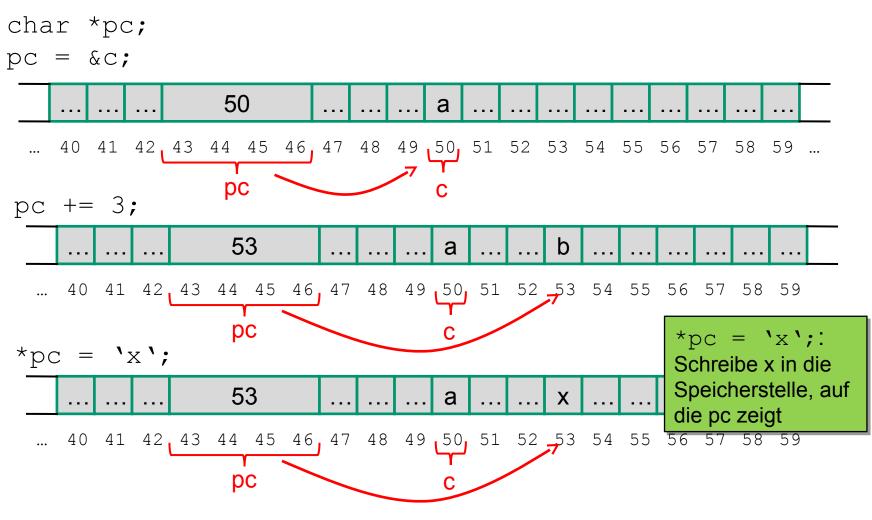
Der Inhalt der Variable "c" wird z.B. in Speicherzelle 50 gespeichert.



Der Inhalt der Variable "pc" wird in Speicherzelle 43 gespeichert (hier: 4 Byte pro Adresse) und ist 50: Die Adresse der Variablen "c"

# **Zeiger und Speicher**

#### Mit Zeigern kann man rechnen! Beispiel:



# Zeiger

- Zugriff auf den Speicherinhalt, auf den ein Zeiger zeigt: \*
  - \*pc = 'x'; schreibt 'x' in die Speicherzelle, auf die pc zeigt
  - char c = \*pc; setzt c auf den Inhalt der Speicherzelle, auf die pc zeigt
- Auch möglich: Zeiger auf Zeiger auf…
  - int \*\*ppc ist ein Zeiger auf einen Zeiger, der auf einen int zeigt
  - Damit möglich: (Mehrdimensionale) Arrays. Der Zeiger zeigt auf einen Speicherbereich, in dem Zeiger auf andere Variablen stehen
  - int \*\*ppc entspricht also int \*ppc[] (mit unbekannter Feldgröße)
  - char \*\*argv ist also ein Zeiger, der auf einen (oder mehrere!) Zeiger auf char zeigt: Array von Strings!
- Zeiger auf Strukturen: Zugriff auf Elemente mit "->" statt "."
   struct point2d \*pp2d;
   pp2d->x = 4.5;
  - pp2d->x äquivalent zu (\*pp2d).x

#### **Zeiger in backwards.c**

#### \*dest++ = argv[i][j]:

- argv[i][j] interpretiert char \*\*argv als zweidimensionales Array von chars
- argv[i][j] ist also der j-te Buchstabe des i-ten Arguments
- \*dest++ schreibt diesen Buchstaben in die Speicherstelle, auf die dest zeigt, und erhöht dest danach um eins

# Kommandozeilenargumente

```
// arg_print.c:
#include <stdio.h>
int main( int argc, char **args ) {
  int i;
  for (i = 0; i < argc; i++)
    printf("Argument %i: %s\n",i,args[i]);
  return 0;
}</pre>
```

```
$ gcc -Wall -o arg_print arg_print.c
$ ./arg_print Dies ist ein Test
Argument 0: ./arg_print
Argument 1: Dies
Argument 2: ist
Argument 3: ein
Argument 4: Test
$ ./arg_print "Dies ist ein Test"
Argument 0: ./arg_print
Argument 1: Dies ist ein Test
```

# Zeiger - Gefahren

# Zeiger sind mächtig, aber gefährlich!



- Bei Zeigerarithmetik ist wichtig, auf was der Zeiger zeigt!
  - char \*pc; pc++; erhöht pc um 1 = sizeof(char)
  - int \*pc; pc++; erhöht pc um sizeof(int)!
- Zur Laufzeit wird nicht geprüft, auf was der Zeiger zeigt!
  - Auf 0
  - auf falsche Variablen
  - Auf Variablen vom falschen Typ
  - mitten ins eigene Programm...

# **Strings**

- Strings in Java: Eigene Klasse mit "eingebauter" Längenverwaltung
- In C: kein eigener String-Typ
- Behelf: char \*
  - Um Speicherplatz für den String muss sich der Programmierer selber kümmern
  - Das Ende eines Strings wird mit einem Null-Byte ,\0' markiert
  - sizeof("hallo") = 6
  - 'h' 'a' 'l' 'l' 'o' '\0'

#### **Strings**

- Viele Bibliotheksfunktionen in <string.h>
  - Kopieren eines Strings
    - char \*strcpy(char \*dest, char \*src);
    - char \*strncpy(char \*dest, char \*src, size t n);
  - Vergleich von zwei Strings
    - int strcmp(const char \*s1, const char \*s2);
    - int strncmp(const char \*s1, const char \*s2, size\_t n);
  - Länge eines Strings
    - size t strlen(const char \*s)
    - \* strlen("hallo") = 5; sizeof("hallo") = 6;
  - Konvertieren von Strings in int/long
    - int atoi(const char \*s)
    - long atol(const char \*s);
  - Zwei Strings aneinanderhängen strcat, strncat
  - Suchen in Strings suchen strchr, strstr
  - **–** ...
- "man 3" und Google wissen mehr!

# printf()

Wichtige Funktion, um Text auf der Konsole auszugeben: printf()

- Syntax: printf("Formatstring", var1, var2, ...);
  - Gibt "Formatstring" auf der Konsole aus
  - var1, ... optional
    - dient dazu, Variablenwerte auszugeben
    - Variablen ersetzen Platzhalter im "Formatstring"
    - Beispiel: printf("Variable a ist %d\n", a);
    - %d: int
    - %s: char \* (String)
    - \* %f: double
    - ...
  - Formatierung möglich
- Varianten: sprintf (Ausgabe in String); fprintf (Ausgabe in Datei), ...
- "man 3 printf" ©

# **Speicherverwaltung**

- Dynamische Objekte in Java: new und Garbage Collector
- In C: Manuelles Speichermanagement durch malloc() und free()

- malloc() allokiert Speicher
  - Mengenangabe in Byte
  - Rückgabe: Ein Zeiger, oder NULL falls Allokation fehlgeschlagen ist
- free() gibt vorher allokierten Speicher wieder frei
  - Nicht vergessen! ©
  - In backwards.c: dest = buffer; wird benötigt, damit Zeiger auf allokierten Speicher für free() nicht verloren geht, da dest in der Schleife verändert wird!

# **Preisfrage**

Was gibt "backwards" bei folgender Eingabe aus?

```
./backwards Zweite Vorlesung Systemnahe Programmierung
```

# **Preisfrage**

#### Warum bricht "backwards" mit einer Fehlermeldung ab?

```
buffer = malloc BUFFER_SIZE); // Speicher reservieren

dest = buffer; // Zeiger merken

for (i = argc-1; i > 0; i--) { // Rückwärts über alle Argumente

for (j = strlen(argv[i])-1; j >= 0; j--) {

*dest++ = argv[i][j]; // char in Puffer schreiben
```

- Die Eingabe "Zweite Vorlesung Systemnahe Programmierung" ist 43 Byte lang und damit länger als der reservierte Puffer: Speicherüberlauf!
- In diesem Fall: Glück, dass nicht andere Variablen überschrieben wurden ⇒ Seiteneffekte. Solche Fehler sind sehr schwer zu finden!
- Solch ein "Buffer Overflow" kann Angriff auf Rechner ermöglichen!
- Lektion: Im Umgang mit Zeigern und Speicher vorsichtig sein!

#### Literatur

- Das war nur eine Auswahl von Grundlagen zu C.
   Vieles wurde nicht erwähnt:
  - typedef, enum, Pointer auf Funktionen, verschiedene
     Sprachstandards (C89, C99, ...), Parameter in Makros,
     Debugger (gdb, ...), Bibliotheken, ...
- Wenn Fragen auftauchen:
  - "man 3" und Google
  - "The C Book" (online): http://publications.gbdirect.co.uk/c\_book/
  - "C for Java Programmers" (online): http://www.cs.vu.nl/~jason/college/dictaat.pdf
  - "Learning C from Java" (online): http://www.comp.lancs.ac.uk/~ss/java2c/
  - Brian W. Kernighan und Dennis Ritchie: "The C Programming Language"
  - Mailingliste