

# Einführung in die Computergrafik

---

Matthias B. Hullin

Institut für Informatik II, Universität Bonn

# Organisatorisches

---

## **Prüfungstermin Klausur 1:**

Mittwoch 7. August 2024, 10:00-12:00, HS1

## **Prüfungstermin Klausur 2:**

Montag 9. September 2024, 10:00-12:00, MA II

# Organisatorisches zum Projekt

Uploadlink:

<https://uni-bonn.sciebo.de/s/yAsHycaf1WYNJld>

**Deliverable 0** (bitte ZIP bis **Di 16. Juli** 23:59 hochladen):

- **Video-Vorschau**, beliebige Qualität/Auflösung
- Verpflichtend!

**Deliverable 1** (bitte ZIP bis **Do 18. Juli** 23:59 hochladen):


- **Kurzfilm-Video** (in hoher Qualität als H.264 codiert)
- **Kurzvortrag** (2 Minuten) als PDF, PPT(x) oder Video
  - Dieser Vortrag ist optional, wenn ein Film eingereicht wurde. Ohne Film ist er **umso wichtiger!**

# Monte Carlo- Integration II

Enthält Material von Jaroslav Křivánek, MFF UK

# Monte-Carlo-Integration

- Allgemeines Werkzeug zur Schätzung bestimmter Integrale



Integral:

$$I = \int f(\mathbf{x}) d\mathbf{x}$$

Monte-Carlo-Schätzwert für  $I$ :

$$\langle I \rangle = \frac{1}{N} \sum_{i=1}^N \frac{f(\xi_i)}{p(\xi_i)}; \quad \xi_i \propto p(\mathbf{x})$$

“Im Mittel” funktioniert es:

$$E[\langle I \rangle] = I$$

# Zufallswerte nach gegebenen Verteilungen

---

# Samples nach diskreter 1D-Verteilung erzeugen

- Gegeben Wahrscheinlichkeitsmassefunktion  $p(i)$ , und die dazugehörige CDF  $P(i)$

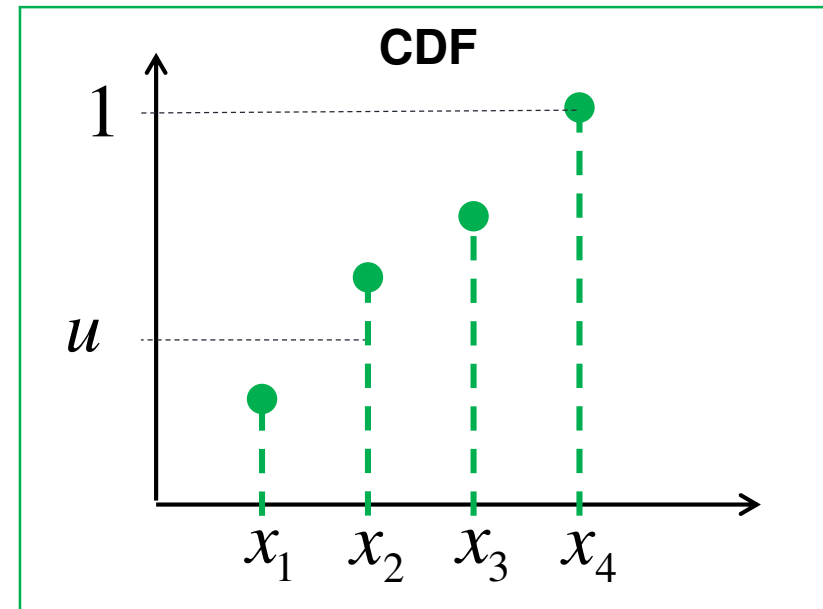
- Schema

1. Erzeuge  $u$  aus  $\text{Uniform}(0,1)$
2. Wähle  $x_i$  für welches

$$P(i-1) < u \leq P(i)$$

(wir definieren  $P(0) = 0$ )

- Die Suche wird üblicherweise durch Intervallschachtelung durchgeführt



# Samples nach diskreter 2D-Verteilung erzeugen

- Gegeben Wahrscheinlichkeitsmassefunktion  $p_{I,J}(i, j)$
- Option 1:
  - Interpretiere 2D PMF als 1D-Vektor von Wahrscheinlichkeiten
  - Erzeuge Zufallswerte wie im 1D-Fall



# Samples nach diskreter 2D-Verteilung erzeugen

- Option 2 (besser)


1. “Spalte”  $i_{\text{sel}}$  wird gemäß Randverteilung (marginal distribution) gewählt, gegeben in Form der 1D marginalen PMF

$$p_I(i) = \sum_{j=1}^{n_j} p_{I,J}(i, j)$$

2. “Zeile”  $j_{\text{sel}}$  wird aus der bedingten Verteilung bei gegebener “Spalte”  $i_{\text{sel}}$  gewählt

$$p_{J|I}(j | I = i_{\text{sel}}) = \frac{p_{I,J}(i_{\text{sel}}, j)}{p_I(i_{\text{sel}})}$$

# Samples nach diskreter 2D-Verteilung erzeugen



# Transformationsmethode vs. Rejection sampling

## ■ Inverse-CDF-Methode (Transformations-Methode)

### **Vorteile**

- Fast immer effizienter als rejection sampling (es sei denn, die Transformationsformel  $x = P^{-1}(u)$  stellt sich als extrem komplex heraus)
- Konstante Zeitkomplexität; Anzahl von Zufallswerten vorab bekannt

## ■ Transformations-Methode **Nachteile**

- Möglicherweise nicht durchführbar (evtl. lässt sich keine geeignete Form für  $x = P^{-1}(u)$  finden), aber rejection sampling ist immer anwendbar, solange wir die PDF auswerten können (d.h., rejection sampling allgemeiner)
- ## ■ Schlaues rejection sampling kann sehr effizient sein (siehe etwa die "Ziggurat method" / Wikipedia)

# Sampling einer kontinuierlichen 2D-Verteilung

- Ähnlich zum 2D diskreten Fall
- Vorgehensweise:
  - Gegeben: Dichte  $p_{X,Y}(x, y) = p_X(x) p_{Y|X}(y | x)$
- 1. Wähle  $x_{\text{sel}}$  gemäß **marginaler PDF**

$$p_X(x) = \int p_{X,Y}(x, y) dy$$

2. Wähle  $y_{\text{sel}}$  gemäß **bedingter PDF**


$$p_{Y|X}(y | X = x_{\text{sel}}) = \frac{p_{X,Y}(x_{\text{sel}}, y)}{p_X(x_{\text{sel}})}$$

# Transformationen für gängige Fälle im Rendering

- P. Dutré: **Global Illumination Compendium**,  
<https://people.cs.kuleuven.be/~philip.dutre/GI/>

## Global Illumination Compendium

### The Concise Guide to Global Illumination Algorithms



Albrecht Dürer, *Unterweisung der Messung mit dem Zirkel und Richtscheit* (Nuremberg, 1525), Book 3, figure 67.

# Importance Sampling der Phong-BRDF

- Strahl trifft Oberfläche mit Phong-BRDF. Wie erzeugen wir den Strahl, um den Lichtpfad fortzusetzen??
- Vorgehensweise
  - Wähle die BRDF-Komponente (diffuse Reflexion, spekulare Reflexion, Brechung, ...)
  - Sample die gewählte Komponente
  - Werte die gesamte PDF und BRDF aus

# Phong-BRDF

$$f_r^{\text{Phong}}(\omega_i \rightarrow \omega_o) = \frac{\rho_d}{\pi} + \frac{n+2}{2\pi} \rho_s \max\{0, \cos \theta_r\}^n$$

- wobei

$$\cos \theta_r = \omega_o \cdot \omega_r$$

$$\omega_r = 2(\omega_i \cdot \mathbf{n})\mathbf{n} - \omega_i$$

- Energieerhaltung:

$$\rho_d + \rho_s \leq 1$$

# Auswahl der BRDF-Komponente

```
pd = max(rhoD.r, rhoD.g, rhoD.b);  
ps = max(rhoS.r, rhoS.g, rhoS.b);  
pd /= (pd + ps);    // prob of choosing the diffuse component  
ps /= (pd + ps);    // prob of choosing the specular comp.  
  
if (rand(0,1) <= pd)  
    genDir = sampleDiffuse();  
else  
    genDir = sampleSpecular(incDir);  
  
pdf = evalPdf(incDir, genDir, pd, ps);
```



# Sampling der diffusen Reflexion

- Importance Sampling mit Dichte  $p(\theta) = \cos(\theta) / \pi$ 
  - $\theta$  ... Winkel zwischen Oberflächennormale und erzeugtem Strahl
  - Erzeuge die Richtung:

$$\begin{aligned} \varphi &= 2\pi r_1 & x &= \cos(2\pi r_1) \sqrt{1 - r_2} \\ \theta &= \arccos(\sqrt{r_2}) & y &= \sin(2\pi r_1) \sqrt{1 - r_2} \\ & & z &= \sqrt{r_2} \end{aligned}$$

- $r_1, r_2$  ... uniforme Zufallsvariablen auf  $[0,1)$
- Referenz: Dutre, Global illumination Compendium (online)
- Herleitung: Pharr/Huphreys/Jakob, PBRT

# sampleDiffuse()

```
// generate spherical coordinates of the direction
float r1 = rand(0,1), r2 = rand(0,1);
float sinTheta = sqrt(1 - r2);
float cosTheta = sqrt(r2);
float phi      = 2.0*PI*r1;
float pdf      = cosTheta/PI;


// convert [theta, phi] to Cartesian coordinates
Vec3 dir (cos(phi)*sinTheta, sin(phi)*sinTheta, cosTheta);

return dir;
```

# Sampling der glänzenden (spekularen) Reflexion

- Importance Sampling mit PDF  $p(\theta) = \frac{n+1}{2\pi} \cos^n(\theta)$ 
  - $\theta$  ... Winkel zwischen idealer Spiegelrichtung von  $\omega_0$  und dem erzeugten Strahl
  - Formeln zum Erzeugen der Richtung:

$$\begin{aligned}\varphi &= 2\pi r_1 & x &= \cos(2\pi r_1) \sqrt{1 - r_2^{\frac{2}{n+1}}} \\ \theta &= \arccos\left(r_2^{\frac{1}{n+1}}\right) & y &= \sin(2\pi r_1) \sqrt{1 - r_2^{\frac{2}{n+1}}} \\ & & z &= r_2^{\frac{1}{n+1}}\end{aligned}$$



- $r_1, r_2$  ... uniforme Zufallsvariablen auf  $[0,1)$

# sampleSpecular()

```
// build a local coordinate frame with R = z-axis
Vec3 R = 2*dot(N,incDir)*N - incDir; // ideal reflected direction
Vec3 U = arbitraryNormal(R);         // U is perpendicular to R
Vec3 V = crossProd(R, U);            // orthonormal basis with R and U

// generate direction in local coordinate frame
Vec3 locDir = rndHemiCosN(n); // formulas form prev. slide, n=phong exp.

// transform locDir to global coordinate frame
Vec3 dir = locDir.x * U + locDir.y * V + locDir.z * R;

return dir;
```

# evalPdf(incDir, genDir, pd, ps)

**return**

```
pd * getDiffusePdf(genDir) +  
ps * getSpecularPdf(incdir, genDir);
```



Formeln von vorigen Folien


# Varianzreduzierung für MC-Schätzer

---

# Methoden zur Varianzreduzierung

- **Importance sampling**
  - Häufigster Ansatz im physikalisch basierten Rendering (meist verwenden wir BRDF-proportionales Importance Sampling)
- **Kontrollvariate**
- **Verbesserte Sampleverteilung**
  - Stratifizierung
  - quasi-Monte Carlo (QMC)

# Importance Sampling






# Importance Sampling

- Teile des Integrationsgebiets mit hohem Wert des Integranden  $f$  sind wichtiger
  - Samples aus diesen Bereichen haben eine höhere Auswirkung aufs Ergebnis
- **Importance Sampling** bevorzugt Auswertung dieser Bereiche
  - d.h., die **PDF**  $p$  ist “ähnlich” zum Integranden  $f$
- **Reduziert Varianz** unter Beibehaltung der Erwartungstreue

# Kontrollvariate



# Kontrollvariante

Betrachte eine Funktion  $g(x)$ , die den **Integranden annähert** und analytisch integrierbar ist:

$$I = \int f(\mathbf{x}) \, d\mathbf{x} = \underbrace{\int [f(\mathbf{x}) - g(\mathbf{x})] \, d\mathbf{x}}_{\text{Numerische Integration (MC)}} + \underbrace{\int g(\mathbf{x}) \, d\mathbf{x}}_{\text{Können wir analytisch integrieren}}$$

Numerische Integration (MC)  
hoffentlich mit geringerer Varianz  
als  $f(x)$  direkt zu integrieren.

Können wir analytisch  
integrieren

# Kontrollvariate vs. Importance Sampling

- **Importance Sampling**


- Vorteilhaft, wenn die Funktion, die wir sampeln wollen, im Integranden als **multiplikativer Faktor** auftaucht (z.B. BRDF in der Reflexionsgleichung)

- **Kontrollvariate**

- Besser, wenn die Funktion, die wir analytisch integrieren können, im Integranden als **additiver Term** auftritt.
- Daher verwenden wir im Rendering fast immer Importance Sampling und fast nie Kontrollvariate.


# Bessere Sampleverteilung

- Erzeugung unabhängiger Samples führt oft zu Klumpenbildung
  - Ergebnis: hohe Varianz des Schätzers
- Bessere Sampleverteilung: => bessere Abdeckung des Integrationsbereichs mit Samples => geringere Varianz
- Ansätze:
  - **Stratifiziertes Sampling** ("geschichtete Zufallsstichprobe")
  - **Quasi-Monte Carlo (QMC)**



# Stratifizierte Abtastung

- Abtastgebiet unterteilt in disjunkte Teilgebiete, die unabhängig voneinander abgetastet werden



# Stratifizierte Abtastung

Unterteilung des Gebietes  $\Omega$  in  $N$  Teile  $\Omega_i$ :

$$I = \int_{\Omega} f(x) \, dx = \sum_{i=1}^N \int_{\Omega_i} f(x) \, dx = \sum_{i=1}^N I_i$$

Resultierender Schätzer:

$$\hat{I}_{\text{strat}} = \frac{1}{N} \sum_{i=1}^N f(X_i), \quad X_i \in \Omega_i$$

# Stratifizierte Abtastung


- Unterdrückt Klumpenbildung
- Reduziert Varianz des Schätzers
  - Varianz beweisbar kleiner oder gleich der eines regulären Sekundärschätzers
- Sehr effektiv in niedrigen Dimensionen
  - Effektivität nimmt für hochdimensionale Integranden ab



# Wie unterteilen wir das Intervall?

- **Uniforme** Unterteilung des Intervalls
  - Natürlicher Ansatz für komplett unbekannten Integranden  $f$
- Wenn die Form des Integranden  $f$  wenigstens grob bekannt ist, streben wir eine Unterteilung an, so dass die Teilgebiete eine kleinstmögliche Varianz haben
- Unterteilung eines  $d$ -dimensionalen Intervalls führt zu  $N^d$  Samples
  - Besserer Ansatz in hohen Dimensionen ist "**N-rooks** sampling".


# Stratified Sampling + Transformationsmethode




# Quasi-Monte-Carlo-Verfahren (QMC)

- Verwende strikt deterministische Folgen statt (Pseudo-) Zufallszahlen
- Pseudo-Zufallszahlen ersetzt durch **low-discrepancy sequences** (Folgen niedriger Diskrepanz)
- Alles funktioniert wie in "normalem" MC, aber die zugrundeliegende Mathematik ist anders (nichts ist zufällig, daher kann die Mathematik nicht auf Wahrscheinlichkeitstheorie aufgebaut werden)

# Diskrepanz




Hohe Diskrepanz  
(Cluster von Punkten)



Niedrige Diskrepanz  
(gleichmäßigere Verteilung)


# Stratified sampling



10 paths per pixel

Henrik Wann Jensen

# Quasi-Monte Carlo



10 paths per pixel

Henrik Wann Jensen



# Same random sequence for all pixels



Henrik Wann Jensen

10 paths per pixel

# Path tracing

---



# Pfade von der Kamera aus verfolgen

```
renderImage()  
{  
  for all pixels  
  {  
    Color pixelColor = (0,0,0);  
    for k = 1 to N  
    {  
      wk := random direction through the pixel  
      pixelColor += getLi(camPos, wk)  
    }  
    pixelColor /= N;  
    writePixel(pixelColor);  
  }  
}
```

# Pathtracing, Version Null (rekursive Form)

**getLi(x,  $\omega$ ):**

$y = \text{traceRay}(x, \omega)$

return

$\text{Le}(y, -\omega) + \text{// emitted radiance}$

$\text{Lr}(y, -\omega) \text{ // reflected radiance}$

**Lr(x,  $\omega$ ):**

$\omega' = \text{genUniformHemisphereRandomDir}(n(x))$

return  $2p * \text{brdf}(x, \omega, \omega')$   
 $\quad * \text{dot}(n(x), \omega') * \text{getLi}(x, \omega')$

# Path Tracing – Schleifenversion

```

getLi(x, w)
{
    Color thrput = (1,1,1)
    Color accum  = (0,0,0)
    while(1)
    {
        hit = NearestIntersect(x, w)
        if no intersection
            return accum + thrput * bgRadiance(x, w)
        if isOnLightSource(hit)
            accum += thrput * Le(hit.pos, -w)
         $\rho = \text{reflectance}(\text{hit.pos}, -w)$ 
        if  $\text{rand}() < \rho$  // russian roulette - survive (reflect)
            wi := SampleDir(hit)
            thrput *= fr(hit.pos, wi, -w) * dot(hit.n, wi) / ( $\rho$  * pdf(wi))
            x := hit.pos
            w := wi
        else // absorb
            break;
    }
    return accum;
}

```

# Pfade abbrechen – Russisch Roulette

- Führe den Pfad mit Wahrscheinlichkeit  $q$  fort
- Multipliziere Gewicht (Durchsatz) der überlebenden Pfade mit  $1/q$

$$Z = \begin{cases} Y / q & \text{if } \xi < q \\ 0 & \text{otherwise} \end{cases}$$

- Russisch Roulette ist unbiased!

$$E[Z] = \frac{E[Y]}{q} \cdot q + 0 \cdot \frac{1}{q-1} = E[Y]$$

# Überlebenswahrscheinlichkeit

- Es ist sinnvoll, die Oberflächenreflektivität  $r$  als Überlebenswahrscheinlichkeit zu verwenden
  - Wenn die Oberfläche nur 30% des Lichts reflektiert, fahren wir mit 30% Wahrscheinlichkeit fort. Dies ist konsistent mit der physikalischen Wirklichkeit.
- Was, wenn wir  $r$  nicht berechnen können? Dann gibt es eine bequeme Alternative:
  - Wähle erst eine zufällige Richtung  $\omega_i$  gemäß  $p(\omega_i)$
  - Verwende dieses  $\omega_i$ , um Überlebenswahrscheinlichkeit zu berechnen:

$$q_{\text{survival}} = \min \left\{ 1, \frac{f_r(\omega_i \rightarrow \omega_o) \cos \theta_i}{p(\omega_i)} \right\}$$

# Richtungssampling

```

getLi(x, w)
{
    Color thrput = (1,1,1)
    Color accum  = (0,0,0)
    while(1)
    {
        hit = NearestIntersect(x, w)
        if no intersection
            return accum + thrput * bgRadiance(x, w)
        if isOnLightSource(hit)
            accum += thrput * Le(hit.pos, -w)
        p = reflectance(hit.pos, -w)
        if rand() < p // russian roulette - survive (reflect)
            wi := SampleDir(hit)
            thrput *= fr(hit.pos, wi, -w) * dot(hit.n, wi) / (p * pdf(wi))
            x := hit.pos
            w := wi
        else // absorb
            break;
    }
    return accum;
}

```

# Richtungssampling

- Wir sampeln die Richtung  $\omega_i$  üblicherweise mit einer PDF ungefähr wie

$$f_r(\omega_i, \omega_o) \cos \theta_i$$

- Idealerweise würden wir proportional zum Integranden sampeln,


$$L_i(\omega_i) f_r(\omega_i, \omega_o) \cos \theta_i,$$

- aber das ist schwierig, weil wir  $L_i$  vorab nicht kennen. Mit einiger Vorberechnung kann man eine grobe Schätzung von  $L_i$  fürs Sampling verwenden [Jensen 95, Vorba et al. 2014].




# Keine Information über einfallende Radianz [Vorba2014]

**Bidirectional path tracing (1h)**





## Guided bidirectional path tracing (1h)



# Importance Sampling der BRDF

- Was passiert, wenn die PDF genau proportional zu  $f_r(\omega_i, \omega_o) \cos \theta_i$  ist?

$$p(\omega_i) \propto f_r(\omega_i \rightarrow \omega_o) \cdot \cos \theta_i$$

- Normalisierung (PDFs müssen zu 1 integrieren)

$$p(\omega_i) = \frac{f_r(\omega_i \rightarrow \omega_o) \cdot \cos \theta_i}{\int_{H(\mathbf{x})} f_r(\omega_i \rightarrow \omega_o) \cdot \cos \theta_i d\omega_i}$$

Dieser Faktor ist nichts anderes als die Reflektanz  $\rho$

# BRDF IS in einem Pathtracer

Durchsatz-Update für eine allgemeine PDF:

```

...
thrput *= f_r(.) * dot(.) / (g * p(w_i))

```

Eine PDF, die genau proportional zu  $\text{BRDF} \cdot \cos$  ist, hält den Durchsatz konstant, weil sich die verschiedenen Terme auslöschen!

$$p(\omega_i) = f_r(\omega_i \rightarrow \omega_o) \cdot \cos \theta_i / \rho$$

```

...
thrput *= 1

```

Physiker nennen dies die “analoge” Simulation, weil sich reale Teilchen so verhalten.

# Direkte Beleuchtung in einem Pathtracer

---

# Direkte Beleuchtung: Zwei Strategien

- An jedem Pfadvertex  $x$ , berechnen wir direkte Beleuchtung
  - d.h. Radianz reflektiert von Punkt  $x$  auf einer Oberfläche, die unmittelbar von den Quellen herrührt
- Zwei Samplingstrategien
  - Sampling proportional zur BRDF
  - Sampling der Lichtquellenfläche






Image: Alexander Wilkie

# Direkte Beleuchtung: Zwei Strategien



BRDF-proportionales Sampling




Lichtquellen-Sampling

Bilder von Eric Veach



# Direktes Licht mit Multiple Importance Sampling




Bilder von Alexander Wilkie

PDF  $p_1$ :  
BRDF-Sampling


PDF  $p_2$ :  
Lichtquellen-Sampling

# Kombination



## Arithmetisches Mittel

Erhält **schlechte** Eigenschaften  
beider Techniken



## Balance heuristic

Bingo!!!

Bilder von Alexander Wilkie



# MIS – Berechnung der Gewichte

Samplegewicht für  
BRDF-Sampling

$$w_1(\omega_j) = \frac{p_1(\omega_j)}{p_1(\omega_j) + p_2(\omega_j)}$$

PDF für BRDF-  
Sampling

**PDF mit der die Richtung  $\omega_j$  erzeugt worden wäre,  
wenn wir Lichtquellensampling verwendet hätten**

- Im Grunde haben wir genau das schon am Anfang der heutigen Vorlesung gemacht – beim Sampeln der verschiedenen Terme der Phong-BRDF

# PDFs

- BRDF-Sampling:  $p_1(\omega)$ 
  - Hängt von der BRDF ab, also etwa für Lambertsche BRDF:

$$p_1(\omega) = \frac{\cos \theta_x}{\pi}$$

- Lichtquellen-Flächensampling:  $p_2(\omega)$

$$p_2(\omega) = \frac{1}{|A|} \frac{\|\mathbf{x} - \mathbf{y}\|^2}{\cos \theta_y}$$

Wandle die uniforme PDF  $1/|A|$  von Flächenmaß ( $dA$ ) zu Raumwinkelmaß ( $d\omega$ )


# Warum der Umwandlungsfaktor?

- PDFs (anders als gewöhnliche Funktionen) ändern sich bei einem Koordinatenwechsel. Im Allgemeinen muss immer erfüllt sein:

$$p(\omega)d\omega = p(\mathbf{y})dA$$

- Und so

$$p(\omega) = p(\mathbf{y}) \frac{dA}{d\omega}$$



Umwandlungsfaktor

# The full picture

---

- Dissertation Eric Veatch, Stanford 1997  
(2 Academy Awards)
- Kapitel 9 über Multiple Importance Sampling