

Grundlagen der Künstlichen Intelligenz

10 Verarbeitung unsicheren Wissens

Wahrscheinlichkeitstheorie, einfache Bayessche Inferenz

Volker Steinhage

Inhalt

- Motivation
- Grundlagen der Wahrscheinlichkeitstheorie
- Probabilistische Inferenz

Motivation

- Oft ist unser Wissen über die Welt mit **Unsicherheiten** behaftet:
- Quellen der Unsicherheiten:
 - 1) nur **partiell beobachtbare** Weltzustände
 - 2) **unzuverlässige** Beobachtungen (z.B. wg. Bewegungsunschärfen)
 - 3) **unsichere** Aktionseffekte
 - 4) **Komplexität** der Modellierung

Problem:

Logik-basierte Planungssysteme gehen aus von

- vollständig beobachtbaren Weltzuständen
- sicheren Aktionsausführungen
- vollständiger Modellierung

Grad der Überzeugung und Wahrscheinlichkeitstheorie

Konsequenz:

- Wir sind von Regeln und Fakten häufig nur „*bis zu einem gewissen Grad überzeugt*“
- Eine Möglichkeit, den **Grad der Überzeugung** auszudrücken, besteht in der Verwendung von **Wahrscheinlichkeiten**

Bspl.: „Der Agent ist von der Sensorinformation zu 90% überzeugt“ heißt: Der Agent nimmt an, dass die Information in 9 von 10 Fällen richtig ist

- Wahrscheinlichkeiten drücken so eine durch partielles Unwissen bedingte **Unsicherheit** aus

Rationale Entscheidungen unter Unsicherheit

Der Agent hat i. A. verschiedene *Aktionen* zur Auswahl

- Diese Aktionen können mit verschiedenen *Wahrscheinlichkeiten* zu verschiedenen Ergebnissen führen
- Diese *Ergebnisse* haben verschiedene *Nutzen*
- Rational wäre es, die Aktion zu wählen, die den größten *zu erwartenden Gesamtnutzen* hat

~ *Entscheidungstheorie* = *Nutzentheorie* & *Wahrscheinlichkeitstheorie*

Entscheidungstheoretischer Agent

function DT-AGENT(*percept*) returns an *action*

static: a set of probabilistic beliefs about the state of the world

calculate updated **probabilities for current state** based on
available evidence including current percept and previous action

calculate **outcome probabilities for actions**,
given action descriptions and probabilities of current states

select *action* with **highest expected utility**

given **probabilities of outcomes** and **utility information**

return *action*

Entscheidungstheorie: Ein **Agent ist rational** gdw. er die **Aktion** wählt, die den **größten zu erwartenden Nutzen** gemittelt über alle möglichen Ergebnisse von **Aktionen** hat.

Wahrscheinlichkeitstheorie: Zufallsvariable

- W'keiten werden ausschließlich *unsicheren* Teilzuständen der Welt zugeordnet
- Elementare Teilzustände werden durch **Zufallsvariablen** benannt
 - Beispiel 1: *Loch* $\in \{true, false\}$ („Loch“ steht hier für kariöses Loch in einem Zahn)
 - Beispiel 2: *Wetter* $\in \{sonnig, regnerisch, wolkig, schnee\}$
- Im weiteren Verlauf werden **Abkürzungen durch Kleinschreibung** benutzt
 - zu Beispiel 1: *loch* für *Loch = true* etc.
 - zu Beispiel 2: *sonnig* für *Wetter = sonnig* etc.
- *Loch = true* ist eine **elementare Aussage** (Proposition)
- Komplexere Aussagen werden mit **logischer Konnektoren** zusammengesetzt
 - Beispiel: $Loch = true \wedge Zahnschmerzen = false$
bzw. $loch \wedge \neg zahnschmerzen$

Atomare Ereignisse

- Eine Aussage, die **allen Zufallsvariablen eines Weltmodells** einen Wert zuweist, wird **atomares Ereignis** genannt
- Unterschiedliche atomare Ereignisse schließen sich wechselseitig aus
- Die Menge aller möglichen atomare Ereignisse ist erschöpfend: genau ein atomares Ereignis muss wahr sein
- Beispiel: Wenn *Loch* und *Zahnschmerzen* die einzigen Zufallsvariablen in der Modellierung einer Zahnpraxisdomänen sind, dann gibt es vier atomare Ereignisse:
 - $loch \wedge zahnschmerzen$
 - $loch \wedge \neg zahnschmerzen$
 - $\neg loch \wedge zahnschmerzen$
 - $\neg loch \wedge \neg zahnschmerzen$

A Priori Wahrscheinlichkeit

$P(a)$ bezeichnet die **unbedingte Wahrscheinlichkeit** oder **A-priori-Wahrscheinlichkeit**, dass die **Aussage a** für den Fall gilt, dass *keine* zusätzliche Information verfügbar ist.

- Beispiel: $P(\text{regnerisch}) = 0.2$
- Wie gewinnt man A-priori-Wahrscheinlichkeiten?
 - durch statistische Analyse
 - aus allgemeinen Regeln

Wahrscheinlichkeitsverteilung

- Im Allgemeinen kann eine **Zufallsvariable** nicht nur die Booleschen Werte *wahr* und *falsch* annehmen, sondern auch mehrere Werte:

Beispiel 1: $P(\text{Wetter} = \text{sonnig}) = 0.7$ $P(\text{Wetter} = \text{regnerisch}) = 0.2$
 $P(\text{Wetter} = \text{wolkig}) = 0.08$ $P(\text{Wetter} = \text{schnee}) = 0.02$

Beispiel 2: $P(\text{Kopfschmerzen} = \text{true}) = 0.1$

-
- $\mathbf{P}(X)$ bezeichnet den **Vektor der Wahrscheinlichkeiten** für den (geordneten) Wertebereich der diskreten **Zufallsvariable** X

Beispiel 1: $\mathbf{P}(\text{Kopfschmerzen}) = \langle 0.1, 0.9 \rangle$

Beispiel 2: $\mathbf{P}(\text{Wetter}) = \langle 0.7, 0.2, 0.08, 0.02 \rangle$

Definiert sind so die **Wahrscheinlichkeitsverteilungen** der diskreten Zufallsvariablen *Kopfschmerzen* bzw. *Wetter*. Die Summe der Werte ist auf 1 normiert.

Bedingte Wahrscheinlichkeiten (1)

Neue Information kann die Wahrscheinlichkeit eines Ereignisses ändern!

- Beispiel: Die W'keit von Karies erhöht sich, wenn man weiß, dass ein Patient Zahnschmerzen hat
- Sobald Zusatzinformation vorliegt, darf nicht mehr mit A-priori-W'keiten gerechnet werden!

- $P(a|b)$ bezeichnet die **bedingte Wahrscheinlichkeit** oder **A-posteriori-Wahrscheinlichkeit** von a , sofern die *alleinige Evidenz* b gegeben ist:

$$P(\text{loch}|\text{zahnschmerzen}) = 0.6$$

- $\mathbf{P}(X|Y)$ ist die **Tabelle aller bedingten W'keiten** über alle Werte von X und Y

Bedingte Wahrscheinlichkeiten (2)

$P(\text{Wetter}|\text{Kopfschmerzen})$ ist eine 4×2 Tabelle von bedingten W'keiten aller Kombinationen der Werte der Zufallsvariablen:

	<i>Kopfschmerzen = true</i>	<i>Kopfschmerzen = false</i>
<i>Wetter = sonnig</i>	$P(W = \text{sonnig} \mid \text{kopfschmerzen})$	$P(W = \text{sonnig} \mid \neg \text{kopfschmerzen})$
<i>Wetter = regnerisch</i>
<i>Wetter = wolkig</i>
<i>Wetter = schnee</i>

Bedingte W'keiten ergeben sich aus unbedingten W'keiten *per Definition* wie folgt ($P(b) > 0$):

$$P(a \mid b) = \frac{P(a \wedge b)}{P(b)} \quad (1)$$

Bedingte Wahrscheinlichkeiten (3)

Aus Gleichung (1) folgt die **Produktregel**:

$$P(a \wedge b) = P(a | b) \cdot P(b). \quad (2)$$

$P(a \wedge b)$ kann auch
geschrieben werden
als $P(a, b)$

Zum Beispiel:

- $P(W = \text{sonnig} \wedge \text{kopfschmerzen}) =$
 $P(W = \text{sonnig} | \text{kopfschmerzen}) \cdot P(\text{kopfschmerzen})$
- $P(W = \text{regnerisch} \wedge \text{kopfschmerzen}) =$
 $P(W = \text{regnerisch} | \text{kopfschmerzen}) \cdot P(\text{kopfschmerzen})$
- ...
- $P(W = \text{schnee} \wedge \neg \text{kopfschmerzen}) =$
 $P(W = \text{schnee} | \neg \text{kopfschmerzen}) \cdot P(\neg \text{kopfschmerzen})$

Bedingte Wahrscheinlichkeiten (4)

- Aus Gleichung (1)

$$P(a | b) = \frac{P(a \wedge b)}{P(b)}$$

folgt also allg. die Produktregel:

$$(2) \quad P(a \wedge b) = P(a | b) \cdot P(b)$$

Analog zu (2) gilt auch:

$$(2') \quad P(a \wedge b) = P(b | a) \cdot P(a)$$

- Zwei Aussagen a und b heißen **unabhängig** voneinander, falls $P(a|b) = P(a)$ und $P(b|a) = P(b)$ gelten. Dann und nur dann gilt:

$$P(a \wedge b) = P(a) \cdot P(b)$$

Warum Wahrscheinlichkeiten? \leadsto axiomat. W'theorie

Folie 4: Eine Möglichkeit, den **Grad der Überzeugung** auszudrücken, besteht in der Verwendung von Wahrscheinlichkeiten

Eine **Funktion** P von Aussagen in die Menge $[0,1]$ ist ein **Wahrscheinlichkeitsmaß**, wenn für alle Aussagen a, b gilt:

$$1) \quad 0 \leq P(a) \leq 1$$

$$2) \quad P(\text{true}) = 1, P(\text{false}) = 0$$

$$3) \quad P(a \vee b) = P(a) + P(b) - P(a \wedge b)$$

Alle anderen Eigenschaften lassen sich aus diesen drei Axiomen ableiten*

Bspl.: $P(\neg a) = 1 - P(a)$ folgt aus $P(a \vee \neg a) = 1$ und $P(a \wedge \neg a) = 0$

* Die drei Axiome werden auch als Kolmogorov-Axiome bezeichnet. Der russ. Mathematiker Andrej Kolmogorov zeigte, dass sich die restl. W-Theorie aus diesen Axiomen ableiten lässt.

Wieso sind die Axiome sinnvoll?

- **Aber** wieso sollte ein Agent diese Axiome beachten, wenn er den *Grad seiner Überzeugung* modelliert?

↪ *Objektive Wahrscheinlichkeiten* vs. *subjektive Wahrscheinlichkeiten*

- Warum subjektive Überzeugungen die Axiome respektieren sollten, zeigte Bruno de Finetti bereits 1931 mit folgendem Satz (s. auch Bspl. im Anhang):

Einem Agenten, der Wetten eingeht und dabei W'keiten zugrunde legt, die den Axiomen widersprechen, können immer Wettstrategien aufgezwungen werden, bei denen er unabhängig vom Ausgang der Ereignisse verliert.

Verbundwahrscheinlichkeit

Bereits bekannt: Ein **atomares Ereignis** ist eine Zuweisung von Werten an *alle* Zufallsvariablen X_1, \dots, X_n (vollständige Spezifikation eines Zustands).

Bspl.: für zwei Boolesche Variablen X, Y gibt es vier atomare Ereignisse:

(1) $X \wedge Y$, (2) $X \wedge \neg Y$, (3) $\neg X \wedge Y$, (4) $\neg X \wedge \neg Y$.

- Eine **Verbundwahrscheinlichkeit** ist die W'keit, die ein Agent *einem atomaren Ereignis* zuordnet.
- Die **Verbundwahrscheinlichkeitsverteilung** $P(X_1, \dots, X_n)$ weist *jedem atomaren Ereignis* eine W'keit zu:

	<i>zahnschmerzen</i>	<i>¬zahnschmerzen</i>
<i>loch</i>	<i>0.12</i>	<i>0.08</i>
<i>¬loch</i>	<i>0.08</i>	<i>0.72</i>

Da alle atomaren Ereignisse disjunkt sind, ist die Summe über alle Felder gleich 1 (Disjunktion der Ereignisse). Die Konjunktion ist notwendigerweise falsch.

Rechnen mit der Verbundwahrscheinlichkeit

Alle interessanten W'keiten lassen sich aus den Verbundwahrscheinlichkeiten errechnen, indem wir sie als Disjunktion von atomaren Ereignissen formulieren.

Beispiel:

	<i>zahnschmerzen</i>	<i>¬zahnschmerzen</i>
<i>loch</i>	0.12	0.08
<i>¬loch</i>	0.08	0.72

1) **Disjunktion** $P(\text{loch} \vee \text{zahnschmerzen}) = P(\text{loch} \wedge \text{zahnschmerzen})$
 $+ P(\neg \text{loch} \wedge \text{zahnschmerzen})$
 $+ P(\text{loch} \wedge \neg \text{zahnschmerzen})$

2) **Unbedingte Wahrscheinlichkeiten** für einzelne Zufallsvariablen erhält man durch Aufsummieren von Zeile oder Spalte (**Marginalisierung**):

$$P(\text{loch}) = P(\text{loch} \wedge \text{zahnschmerzen}) + P(\text{loch} \wedge \neg \text{zahnschmerzen})$$

3) Womit **bedingte Wahrscheinlichkeiten** ableitbar sind:

$$P(\text{loch} \mid \text{zahnschmerzen}) = \frac{P(\text{loch} \wedge \text{zahnschmerzen})}{P(\text{zahnschmerzen})} = \frac{0.12}{0.12 + 0.08} = 0.60$$

Probleme mit der Verbundwahrscheinlichkeit

Pro: Aus den Verbundwahrheiten lassen sich alle Wahrheiten ermitteln

Con: Aber die Verbundwahrscheinlichkeitsverteilung umfasst k^n Werte, wenn es n Zufallsvariablen mit k Werten gibt

~ schwierig darzustellen und schwierig zu ermitteln

Fragen:

- Gibt es *kompaktere* Darstellungen von Verbundwahrscheinlichkeiten?
- Gibt es *effiziente* Methoden, diese Darstellung zu verarbeiten?

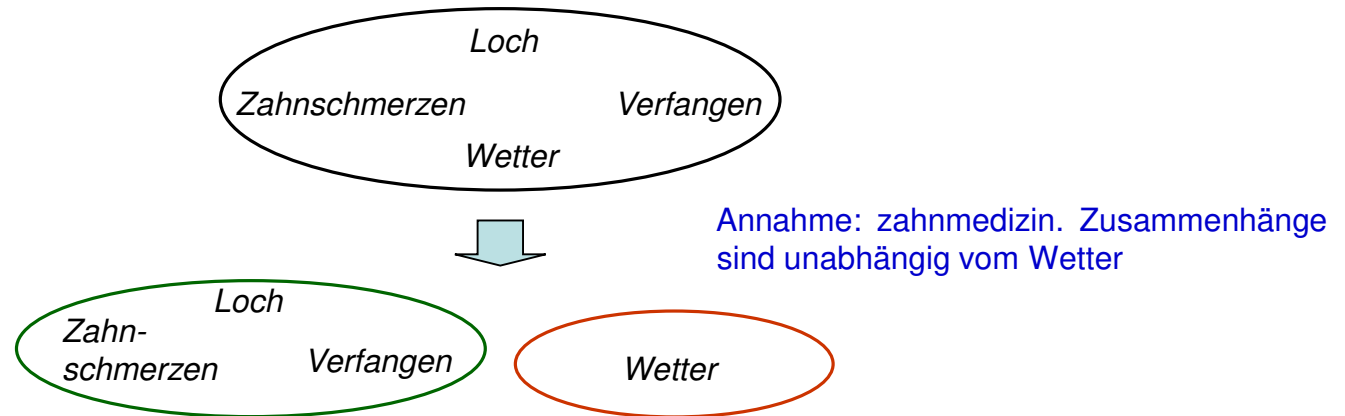
Als Antworten werden in dieser Vorlesung behandelt:

- das Ausnutzen von Unabhängigkeiten
- das Ableiten über die Bayessche Regel

Absolute Unabhängigkeit

Sind einige Variablen in der Verbundverteilung **unabhängig** von den übrigen, kann die Verbundverteilung zerlegt werden

Beispiel:



$$\begin{aligned} \rightarrow & \mathbf{P}(\text{Zahnschmerzen}, \text{Verfangen}, \text{Loch}, \text{Wetter}) \\ &= \mathbf{P}(\text{Zahnschmerzen}, \text{Verfangen}, \text{Loch}) \cdot \mathbf{P}(\text{Wetter}) \end{aligned}$$

→ $2^3 \cdot 4 = 8 \cdot 4 = 32$ Einträge werden auf $8 + 4 = 12$ reduziert (4 mögl. Werten für Wetter)

Konditionale Unabhängigkeit (1)

$P(\text{Zahnschmerzen}, \text{Verfangen}, \text{Loch})$ hat 7 ($= 2^3 - 1$) *unabhängige* Einträge.
Daraus sind u.a. ableitbar:

- Liegt Karies vor, ist die W'keit dafür, dass der Zahnarzt durch Verfangen des Hakens das Loch entdeckt, unabhängig davon, ob Zahnschmerzen vorliegen:

$$\leadsto P(\text{verfangen} \mid \text{zahnschmerzen}, \text{loch}) = P(\text{verfangen} \mid \text{loch})$$

- Die gleiche Unabhängigkeit gilt für den Fall, dass kein Karies vorliegt:

$$\leadsto P(\text{verfangen} \mid \text{zahnschmerzen}, \neg \text{loch}) = P(\text{verfangen} \mid \neg \text{loch})$$

\leadsto Verfangen ist *konditional unabhängig* (bzw. *bedingt unabhängig*) von Zahnschmerzen gegeben die Evidenz für Loch

- Zusicherungen von Unabhängigkeiten basieren i. A. auf Domänenwissen!

Konditionale Unabhängigkeit (2)

Die allg. Definition der bedingten Unabhängigkeit von **zwei Variablen X und Y** bei einer gegebenen **dritten Variablen Z** lautet:

$$(1) \quad \mathbf{P}(X|Y,Z) = \mathbf{P}(X|Z) \text{ sowie } \mathbf{P}(Y|X,Z) = \mathbf{P}(Y|Z) \quad (\text{s. Folie 24})$$

bzw.

$$(2) \quad \mathbf{P}(X,Y|Z) = \mathbf{P}(X|Z) \cdot \mathbf{P}(Y|Z)$$

(2) am Beispiel:

$$\begin{aligned} &\mathbf{P}(\text{Zahnschmerzen, Verfangen} \mid \text{Loch}) \\ &= \mathbf{P}(\text{Zahnschmerzen} \mid \text{Loch}) \cdot \mathbf{P}(\text{Verfangen} \mid \text{Loch}) \end{aligned}$$

Konditionale Unabhängigkeit (3)

Die vollständige Verbundverteilung erhält man über die Produktregel (s. F. 13):

$$\mathbf{P}(\text{Zahnschmerzen}, \text{Verfangen}, \text{Loch})$$

$$= \mathbf{P}(\text{Zahnschmerzen} \mid \text{Verfangen}, \text{Loch}) \cdot \mathbf{P}(\text{Verfangen}, \text{Loch})$$

$$= \mathbf{P}(\text{Zahnschmerzen} \mid \text{Verfangen}, \text{Loch}) \cdot \mathbf{P}(\text{Verfangen} \mid \text{Loch}) \cdot \mathbf{P}(\text{Loch})$$

$$= \mathbf{P}(\text{Zahnschmerzen} \mid \text{Loch}) \cdot \mathbf{P}(\text{Verfangen} \mid \text{Loch}) \cdot \mathbf{P}(\text{Loch})$$

~ $2 \cdot (2 \cdot (2^1 - 1)) + 2^1 - 1 = 5$ unabhängige Einträge statt $(2^3 - 1) = 7$:

L	P(z L)
t	0.4
f	0.011

L	P(v L)
t	0.9
f	0.2

L	P(l)
t	0.2

Ggf. kann die Größe der Repräsentation von Verbundverteilungen durch Ausnutzung von konditionalen Unabhängigkeiten von „exponentiell in der Anzahl der Variablen n “ auf „linear in n “ reduziert werden!

Zur Inferenz \leadsto die Bayessche Regel

Wir wissen aus der Produktregel:

$$P(a \wedge b) = P(a|b) \cdot P(b) \quad \text{und} \quad P(a \wedge b) = P(b|a) \cdot P(a)$$

Durch *Gleichsetzen der beiden rechten* Seiten folgt:

$$P(a|b) \cdot P(b) = P(b|a) \cdot P(a)$$

Durch einfache Umformung: $P(a|b) = \frac{P(b|a) \cdot P(a)}{P(b)}$

... und für Verteilungen: $P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$

Nützlich, um *diagnostische* Wahrscheinlichkeiten von *kausalen* abzuleiten:

$$P(\text{Ursache} | \text{Wirkung}) = \frac{P(\text{Wirkung} | \text{Ursache}) \cdot P(\text{Ursache})}{P(\text{Wirkung})}$$

Anwendung der Bayesschen Regel

Geg. seien:	$P(\text{zahnschmerzen} \text{loch}) = 0.6$	(kausal)
	$P(\text{loch}) = 0.2$	(Statistik)
	$P(\text{zahnschmerzen}) = 0.2$	(Statistik)
mit Bayes-Regel:	$P(\text{loch} \text{zahnschmerzen}) = \frac{0.6 \cdot 0.2}{0.2} = 0.6$	

Frage: Warum nicht gleich $P(\text{loch}|\text{zahnschmerzen})$ schätzen?

- Die kausale Regel $P(\text{zahnschmerzen}|\text{loch})$ ist unabhängig von den A-priori-W'keiten $P(\text{loch})$ und $P(\text{zahnschmerzen})$
 - nähme $P(\text{loch})$ bei einer Kariesepidemie zu, so bliebe die Kausalität $P(\text{zahnschmerzen}|\text{loch})$ unverändert, während sich $P(\text{zahnschmerzen})$ proportional mit $P(\text{loch})$ änderte.
 - ein Arzt, der $P(\text{loch}|\text{zahnschmerzen})$ aus Daten geschätzt hätte, müsste von vorne anfangen

Allgemein: Kausales Wissen wie $P(\text{zahnschmerzen} | \text{loch})$ ist i.A. robuster als diagnostisches Wissen wie $P(\text{loch} | \text{zahnschmerzen})$

Normalisierung (1)

Ziel: Bestimmung der Wahrscheinlichkeit von $P(\text{loch}|\text{zahnschmerzen})$

Problem: $P(\text{zahnschmerzen})$ sei unbekannt

Lösung: $P(\text{loch}|\text{zahnschmerzen})$ ist durch *vollständige Fallanalyse* herleitbar

Hier Fallanalyse über loch und $\neg\text{loch}$ sowie den Zusammenhang

$$P(\text{loch}|\text{zahnschmerzen}) + P(\neg\text{loch}|\text{zahnschmerzen}) = 1$$

Hier aus Platzgründen:
 $\text{zahnschmerzen} = z$ und
 $\text{loch} = l$.

$$P(l | z) = \frac{P(z | l)P(l)}{P(z)}$$

$$P(\neg l | z) = \frac{P(z | \neg l)P(\neg l)}{P(z)}$$

$$P(l | z) + P(\neg l | z) = 1 = \frac{P(z | l)P(l)}{P(z)} + \frac{P(z | \neg l)P(\neg l)}{P(z)}$$

$$P(z) = P(z | l)P(l) + P(z | \neg l)P(\neg l)$$



Normalisierung (2)

Durch Einsetzen in die ersten beiden Gleichungen:

$$P(l | z) = \frac{P(z | l) P(l)}{P(z | l) P(l) + P(z | \neg l) P(\neg l)}$$

$$P(\neg l | z) = \frac{P(z | \neg l) P(\neg l)}{P(z | l) P(l) + P(z | \neg l) P(\neg l)}$$

Dieser Prozess heißt **Normalisierung**, weil $1/P(z)$ einfach als Normalisierungskonstante genutzt werden kann, um die Summe der bedingten W'keiten gleich 1 zu setzen.

- Für *mehrwertige* Zufallsvariablen allgemein:

$$\mathbf{P}(Y|X) = \alpha \cdot \mathbf{P}(X|Y) \cdot \mathbf{P}(Y)$$

- Wobei α die **Normierungskonstante** ist, die die Summe der Werte in $\mathbf{P}(Y|X)$ über alle Y auf 1 normiert, z.B. $\alpha = 1/5$ für $\langle 1, 1, 3 \rangle$ damit $1/5 + 1/5 + 3/5 = 1$

Normalisierung (3): Beispiel

Geg. sei das Zahnarztszenario jetzt durch folgende Verbundw.-Verteilung:

	zahnschmerzen		\neg zahnschmerzen	
	verfangen	\neg verfangen	verfangen	\neg verfangen
loch	0.108	0.012	0.072	0.008
\neg loch	0.016	0.064	0.144	0.576

$$\Rightarrow P(\text{loch} \mid \text{zahnschmerzen}) = \frac{P(\text{loch} \wedge \text{zahnschmerzen})}{P(\text{zahnschmerzen})} = \frac{0.108 + 0.012}{0.108 + 0.012 + 0.016 + 0.064} = 0.6$$

$$\Rightarrow P(\neg \text{loch} \mid \text{zahnschmerzen}) = \frac{P(\neg \text{loch} \wedge \text{zahnschmerzen})}{P(\text{zahnschmerzen})} = \frac{0.016 + 0.064}{0.108 + 0.012 + 0.016 + 0.064} = 0.4$$

Mit Normalisierung in einer Gleichung formulierbar:

s. F. 12: $P(a \mid b) = \frac{P(a \wedge b)}{P(b)}$

$$\begin{aligned}
 P(\text{Loch} \mid \text{zahnschmerzen}) &= \alpha \cdot P(\text{Loch}, \text{zahnschmerzen}) \\
 &= \alpha \cdot [P(\text{Loch}, \text{zahnschmerzen}, \text{verfangen}) + P(\text{Loch}, \text{zahnschmerzen}, \neg \text{verfangen})] \\
 &= \alpha \cdot [\langle 0.108; 0.016 \rangle + \langle 0.012; 0.064 \rangle] \\
 &= \alpha \cdot \langle 0.12; 0.08 \rangle \\
 &= \langle 0.6; 0.4 \rangle
 \end{aligned}$$

Die Belegung von *Verfangen* ist für $P(\text{Loch} \mid \text{zahnschmerzen})$ nicht festgelegt. Also ist über alle (hier zwei) mögl. Werte zu summieren.

Normalisierung 4

Verallgemeinert aus dem Beispiel sind gegeben:

- Anfragevariable X (im Beispiel *Loch*)
- Menge E der beobachteten Evidenzvariablen (im Beispiel *zahnschmerzen*) und e die beobachteten Werte für diese
- Menge Y der restlichen unbeobachteten Variablen (im Beispiel *verfangen*) und y die möglichen Werte für diese

Die Auswertung der Anfrage $P(X | e)$ ist dann:

$$P(X | e) = \alpha \cdot P(X, e) = \alpha \cdot \sum_y P(X, e, y)$$

Wumpus Welt

Unsicherheit entsteht hier, da die Sensoren nur partielle Information liefern:

- Hier hat der Agent in [1,2] und [2,1] einen Luftzug (B) erkannt.
- Jedes der erreichbaren Felder [1,3], [2,2], [3,1] kann eine Falltür enthalten.
- Ein logischer Agent müsste probieren ... mit nicht kalkulierbarem Risiko
- Ein probabilistischer Agent ist besser:

Kodierung: $P_{ij} = \text{true}$ gdw. $[i,j]$ enthält Fallgrube (Pit)

$B_{ij} = \text{true}$ gdw. $[i,j]$ ist „breezy“

Gegeben sind nur die Wahrnehmungen B_{11} , B_{12} , B_{21}

1,4	2,4	3,4	4,4
1,3	2,3	3,3	4,3
1,2 B OK	2,2	3,2	4,2
1,1 OK	2,1 B OK	3,1	4,1

In diesem Bspl. werden nur Luftzüge und Falltüren betrachtet → also werden hier Wumpus und Gold nicht berücksichtigt.

Frage: wie wahrscheinlich sind Fallgruben in den gelben Feldern?

Spezifikation des Wahrscheinlichkeitsmodells

- Vollständ. Verbundverteilung: $P(P_{11}, \dots, P_{44}, B_{11}, B_{12}, B_{21})$.

→ Anwendung der Produktregel:

$$P(B_{11}, B_{12}, B_{21} \mid P_{11}, \dots, P_{44}) \cdot P(P_{11}, \dots, P_{44})$$

→ Warum?

1,4	2,4	3,4	4,4
1,3	2,3	3,3	4,3
1,2 B OK	2,2	3,2	4,2
1,1 OK	2,1 B OK	3,1	4,1

- Um kausale Beziehung $P(\text{Wirkung} \mid \text{Ursache})$ zu erhalten:
 - *Modell für ersten Term* (Kombination Luftzug und benachbarte Falltür):
1 für Luftzug, falls direkt benachbart zu Fallgruben, sonst 0.
 - *Modell für zweiten Term*: Fallgruben seien *zufällig* und *unabhängig* verteilt mit W'keit 20% pro Feld, d.h.:

$$P(P_{11}, \dots, P_{44}) = \prod_{(i,j) \in \{(1,1), \dots, (4,4)\}} P(P_{ij})$$

→ $P(\text{Konfiguration mit exakt } n \text{ Fallgruben}) = 0,2^n \cdot 0,8^{16-n}$

○

Beobachtungen und Anfrage

Wir kennen die folgenden **Fakten**:

$$b = \neg b_{11} \wedge b_{12} \wedge b_{21}$$

$$\text{known} = \neg p_{11} \wedge \neg p_{12} \wedge \neg p_{21}$$

1,4	2,4	3,4	4,4
1,3	2,3	3,3	4,3
1,2 B OK	2,2	3,2	4,2
1,1 OK	2,1 B OK	3,1	4,1

Wir wollen zunächst wissen, wie wahrscheinlich in P_{13} eine Fallgrube ist:

→ Anfrage: $P(P_{13} \mid \text{known}, b)$

Definiere: *unknown* als „alle Felder außer P_{13} und den Feldern aus *known*“

→ Jetzt gilt: $P(P_{13} \mid \text{known}, b) = \alpha \cdot \sum_{\text{unknown}} P(P_{13}, \text{unknown}, \text{known}, b)$

Ausnutzung konditionaler Unabhängigkeit (1)

Damit haben wir eine **Ableitungsvorschrift**:

$$\mathbf{P}(P_{13} \mid \text{known}, b) = \alpha \cdot \sum_{\text{unknown}} \mathbf{P}(P_{13}, \text{unknown}, \text{known}, b)$$

Aber wir vernachlässigen die **Berechnungskomplexität**: Wir müssen über 12 unbekannte Felder summieren \rightarrow die Summe enthält $2^{12} = 4096$ Terme

Grundlegende Einsicht: z.B. Feld [4,4] wird in der Wumpus-Welt wenig Aufschluss über Feld [1,3] geben

1,4	2,4	3,4	4,4
1,3	2,3	3,3	4,3
1,2 B OK	2,2	3,2	4,2
1,1 OK	2,1 B OK	3,1	4,1

Generell: *die Beobachtungen (breezes) sind unabhängig* von den übrigen unbekannten Feldern, wenn ihre direkten Nachbarfelder gegeben sind

Wir definieren als **Rand (fringe)** die **Felder, die neben den besuchten Feldern liegen, aber nicht Anfragefeld sind**. Damit gelten $\text{unknown} = \text{fringe} \cup \text{other}$ und


$$\mathbf{P}(b \mid P_{13}, \text{known}, \text{unknown}) = \mathbf{P}(b \mid P_{13}, \text{known}, \text{fringe})$$

Ausnutzung konditionaler Unabhängigkeit (2)

Wir definieren als **Rand** (*fringe*) die **Felder**, die neben den besuchten Feldern liegen, aber nicht Anfragefeld sind → es gelten $unknown = fringe \cup other$ und

$$\mathbf{P}(b \mid P_{13}, known, unknown) = \mathbf{P}(b \mid P_{13}, known, fringe)$$

1,4	2,4	3,4	4,4
1,3	2,3	3,3	4,3
1,2 B OK	2,2	3,2	4,2
1,1 OK	2,1 B OK	3,1	4,1



Jetzt formen wir die Anfrage so um, dass wir dies ausnutzen können!

Ausnutzung konditionaler Unabhängigkeit (3)

$$\mathbf{P}(P_{13} \mid \text{known}, b)$$

$$\text{s. F. 29: } \mathbf{P}(X \mid \mathbf{e}) = \alpha \cdot \mathbf{P}(X, \mathbf{e}) = \alpha \cdot \sum_{\mathbf{y}} \mathbf{P}(X, \mathbf{e}, \mathbf{y})$$

$$= \alpha \cdot \sum_{\text{unknown}} \mathbf{P}(P_{13}, \text{unknown}, \text{known}, b)$$

kausal durch Produktregel

$$= \alpha \cdot \sum_{\text{unknown}} \mathbf{P}(b \mid P_{13}, \text{known}, \text{unknown}) \cdot \mathbf{P}(P_{13}, \text{known}, \text{unknown})$$

umformuliert

$$= \alpha \cdot \sum_{\text{fringe}} \sum_{\text{other}} \mathbf{P}(b \mid \text{known}, P_{13}, \text{fringe}, \text{other}) \cdot \mathbf{P}(P_{13}, \text{known}, \text{fringe}, \text{other})$$

bed. Unabh.

$$= \alpha \cdot \sum_{\text{fringe}} \sum_{\text{other}} \mathbf{P}(b \mid \text{known}, P_{13}, \text{fringe}) \cdot \mathbf{P}(P_{13}, \text{known}, \text{fringe}, \text{other})$$

$$= \alpha \cdot \sum_{\text{fringe}} \mathbf{P}(b \mid \text{known}, P_{13}, \text{fringe}) \cdot \sum_{\text{other}} \mathbf{P}(P_{13}, \text{known}, \text{fringe}, \text{other})$$

Unabhängigkeit

$$= \alpha \cdot \sum_{\text{fringe}} \mathbf{P}(b \mid \text{known}, P_{13}, \text{fringe}) \cdot \sum_{\text{other}} \mathbf{P}(P_{13}) \cdot \mathbf{P}(\text{known}) \cdot \mathbf{P}(\text{fringe}) \cdot \mathbf{P}(\text{other})$$


$$= \alpha \cdot \mathbf{P}(\text{known}) \cdot \mathbf{P}(P_{13}) \cdot \sum_{\text{fringe}} \mathbf{P}(b \mid \text{known}, P_{13}, \text{fringe}) \cdot \mathbf{P}(\text{fringe}) \sum_{\text{other}} \mathbf{P}(\text{other})$$

$$= \alpha' \cdot \mathbf{P}(P_{13}) \cdot \sum_{\text{fringe}} \mathbf{P}(b \mid \text{known}, P_{13}, \text{fringe}) \cdot \mathbf{P}(\text{fringe})$$

Wobei zuletzt $\mathbf{P}(\text{known})$ in die Normalisierungskonstante aufgenommen wird und genutzt wird, dass $\sum_{\text{other}} \mathbf{P}(\text{other})$ gleich 1 ist.

Ausnutzung konditionaler Unabhängigkeit (4)

- Bei $P(P_{13} | \text{known}, b) = \alpha' \cdot P(P_{13}) \cdot \sum_{\text{fringe}} P(b | \text{known}, P_{13}, \text{fringe}) \cdot P(\text{fringe})$ ist $P(b | \text{known}, P_{13}, \text{fringe}) = 1$, wenn *fringe* konsistent mit *b* ist, sonst 0
- Wir summieren für jeden P_{13} -Wert nur über die logischen Modelle des Randes, die konsistent mit den Fakten sind
- Fünf konsistente „Fringe“-Zustände mit $P(b | P_{13}, \text{known}, \text{fringe}) = 1$ für p_{13} und $\neg p_{13}$:



- $P(P_{13} | \text{known}, b) = \alpha' \cdot \langle 0.2 \cdot (0.04 + 0.16 + 0.16), 0.8 \cdot (0.04 + 0.16) \rangle$
 $\approx \langle 0.31, 0.69 \rangle$
- $P(P_{31} | \text{known}, b) \approx \langle 0.31, 0.69 \rangle$ wg. Symmetrie
- $P(P_{22} | \text{known}, b) \approx \langle 0.86, 0.14 \rangle$

→ Es ist also kalkulierbar, das es günstiger ist, am Rand entlang zu laufen

Zusammenfassung

- **Unsicherheit** ist unvermeidbar in komplexen und dynamischen Welten, in denen Agenten zur Ignoranz gezwungen sind.
- **Wahrscheinlichkeiten** formulieren die Unfähigkeit eines Agenten, eine definitive Entscheidung zu fällen. Sie drücken den Grad seiner Überzeugung aus.
- **Bedingte** und **unbedingte** Wahrscheinlichkeiten können über Propositionen formuliert werden.
- Alle relevanten Wahrscheinlichkeiten können durch Summation der Wahrscheinlichkeiten atomarer Ereignisse aus der **Verbundverteilung** ermittelt werden.
- Für nicht triviale Domänen ist es erforderlich, eine **effiziente Repräsentation** der Verbundverteilung zu finden.
- **Unabhängigkeit** und **konditionale Unabhängigkeit** sind die Werkzeuge dafür.
- **Produktregel** und **Bayessche Regel** ermöglichen es dabei, Anfragen geeignet umzuformen.

Anhang: Ein Wettspiel nach de Finetti

- **Agent 1** hat die Überzeugung $P(a) = 0.4$, dass ein Ereignis a eintritt.
- **Agent 2** kann für oder gegen a wetten, sein Einsatz muss dabei jedoch konsistent mit der Überzeugung von **Agent 1** sein (faire Wette).
- **Beispiel:** **Agent 2** setzt 4 zu 6 auf a , d.h. tritt a auf, muss **Agent 1** den Betrag von 6 Euro an Agent 2 zahlen, sonst zahlt **Agent 2** den Betrag von 4 Euro an **Agent 1**.

Agent 2 wettet:	Agent 1 muss dagegenhalten:
a tritt auf: 4 Euro	a tritt nicht auf: 6 Euro
a tritt nicht auf: 6 Euro	a tritt auf: 4 Euro

~ Nach de Finetti muss **Agent 1** diese Wette akzeptieren (weil sie fair ist).

Eine Wettstrategie ist eine Menge von Wetten auf mehrere Ereignisse.

Anhang: Das Wettmodell

Agent 1 habe die folgenden Grade von Überzeugungen:

$$P(a) = 0.4, P(b) = 0.3, P(a \wedge b) = 0.0, P(a \vee b) = 0.8$$

↗ **Widerspruch zu 3. Axiom der W-Theorie:** $P(a \vee b) \neq P(a) + P(b) - P(a \wedge b)$

Agent 2 habe die Wettstrategie:

$a, b, \neg(a \vee b)$ und

setzt 4 zu 6 auf a , 3 zu 7 auf b und 2 zu 8 auf $\neg(a \vee b)$:

Agent 1		Agent 2		Ergebnisse für Agent 1 bei			
Aussage	Glaube	Wette	Einsatz	$a \wedge b$	$a \wedge \neg b$	$\neg a \wedge b$	$\neg a \wedge \neg b$
a	0.4	a	4 zu 6	-6	-6	4	4
b	0.3	b	3 zu 7	-7	3	-7	3
$a \vee b$	0.8	$\neg(a \vee b)$	2 zu 8	2	2	2	-8
				-11	-1	-1	-1

Setzt Agent 2 entspr. seiner Strategie, verliert **Agent 1** bei allen möglichen Ergebnissen für a und b .